ĐẠI HỌC KINH TẾ QUỐC DÂN

VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE

BÀI TẬP NHÓM

KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

CHỦ ĐỀ 10: BÁO CÁO PHÂN TÍCH BỘ DỮ LIỆU LOAN DEFAULT.

Giảng viên: TS. Trần Đức Minh

Nhóm: 03

Thành viên: Nguyễn Cẩm Lê - 11248265
Ninh Thị Thu Phương - 11240557
Phạm Quỳnh Anh - 11244805
Trịnh Minh Châu - 11245183
Phạm Nguyễn Nhật Linh - 11240520

Lớp học phần: AEP.TOKT1138.LS(126)_01

Mã nguồn GitHub: https://github.com/quale2006-art/CLC66A--NH-M-3/tree/main/GROUP3

Hà Nội, 2026

Phân tích bộ dữ liệu Loan Default

Nguồn dữ liệu: Loan Default Dataset - Kaggle

Quy mô: 148.670 hồ sơ khoản vay với 34 thuộc tính.

Nội dung

- **Thiết lập môi trường:** Chuẩn bị thư viện và tải dữ liệu trên Google Colab.
- **Giai đoạn 1 - Khám phá dữ liệu:** Kiểm tra cấu trúc, dữ liệu thiếu và tính nhất quán.
- **Giai đoạn 2 - Tiền xử lý:** Làm sạch dữ liệu, kiểm tra ngoại lệ và giải thích phương pháp xử lý.
- **Giai đoạn 3 - Phân tích:** Kiểm định giả thuyết, trực quan hóa và nhận xét kết quả.
- **Giai đoạn 4 - Kết luận:** Tổng hợp phát hiện, khuyến nghị và giới hạn nghiên cứu.

Quy ước về Status

- **Status = 0:** Khoản vay không vỡ nợ (*Non-default*).
- **Status = 1:** Khoản vay vỡ nợ (*Default*).

Cách phân loại này được tham khảo từ các dự án sử dụng cùng bộ dữ liệu; Kaggle chưa cung cấp định nghĩa chính thức cho hai nhãn.

Giai đoạn 0. Thiết lập môi trường và tải dữ liệu

Dữ liệu được tải theo thứ tự sau:

1. Sử dụng file Loan_Default.csv nếu đã có sẵn.
2. Nếu không tìm thấy, tải từ Kaggle bằng kagglehub.
3. Nếu không tải được từ Kaggle, tải file CSV lên Colab thủ công.

Giai đoạn 1. Thu thập và đánh giá dữ liệu ban đầu

1.1. Mục tiêu phân tích

Giai đoạn này tập trung vào việc tìm hiểu bộ dữ liệu trước khi tiến hành làm sạch và phân tích.

Các mục tiêu chính:

4. Kiểm tra số lượng dòng, cột và kiểu dữ liệu của từng thuộc tính.
5. Xác định các giá trị bị thiếu, dữ liệu trùng lặp và những điểm không nhất quán.
6. Tìm hiểu các thuộc tính để chuẩn bị cho bước tiền xử lý và phân tích ở những giai đoạn tiếp theo.

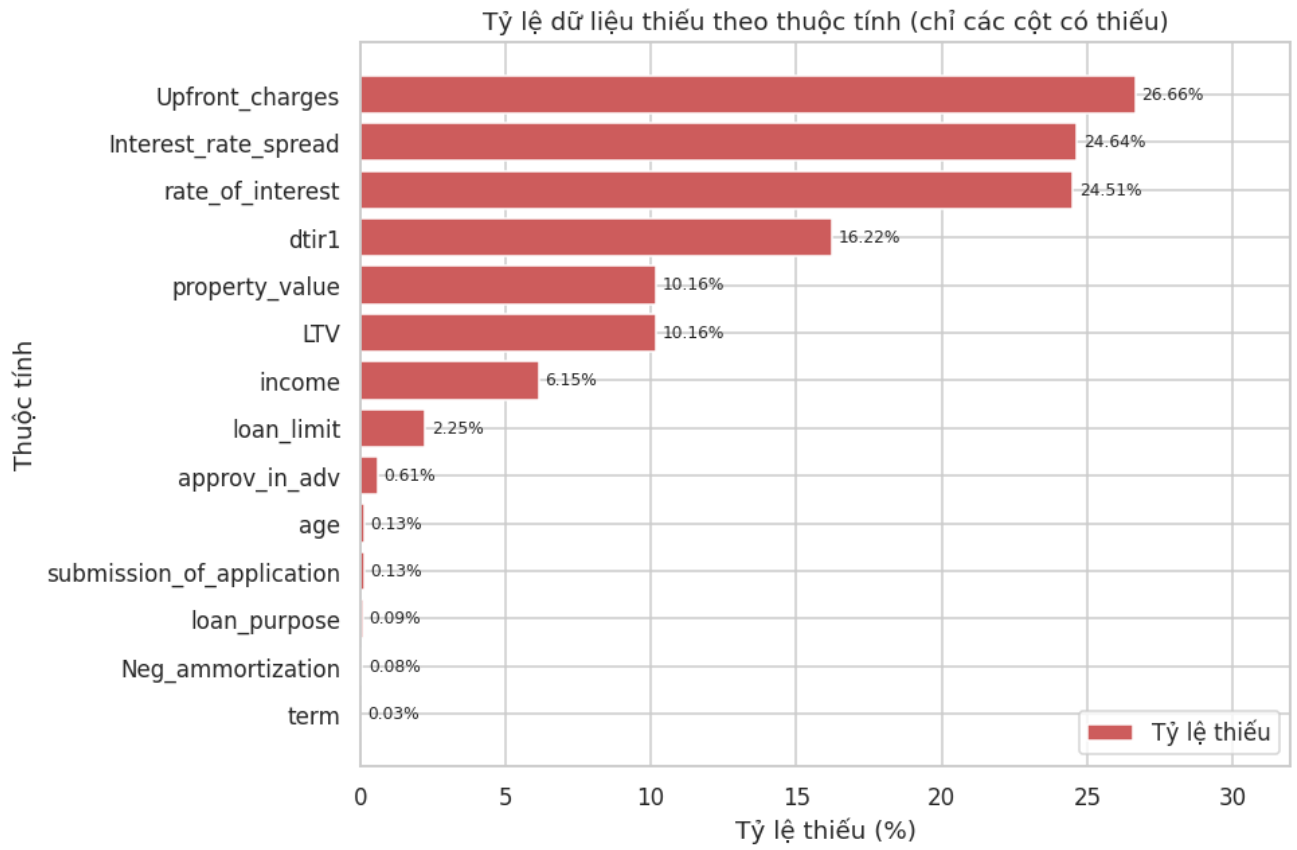
Nhận xét: Bộ dữ liệu gồm 148.670 dòng và 34 cột, trong đó có 13 cột dữ liệu số và 21 cột dữ liệu dạng chuỗi. Các mã ID tăng liên tục từ 24.890 đến 173.559. Cột year chỉ chứa giá trị 2019 nên không thể phân tích xu hướng theo thời gian.

Nhận xét:

- loan_amount, income và property_value có giá trị trung bình cao hơn trung vị, đồng thời giá trị lớn nhất vượt xa phân vị 99%. Điều này cho thấy dữ liệu có xu hướng lệch phải và cần kiểm tra các giá trị ngoại lệ.
- LTV có giá trị lớn nhất lên tới 7.831,25%, trong khi phân vị 99% chỉ khoảng 102,76%. Đây là giá trị bất thường cần kiểm tra kỹ hơn.
- income và rate_of_interest đều có giá trị nhỏ nhất bằng 0, cần xem xét tính hợp lý.
- Credit_Score nằm trong khoảng 500-900, với trung bình khoảng 700. dtir1 dao động từ 5 đến 61.

Các giá trị bất thường sẽ được kiểm tra chi tiết ở Giai đoạn 2.

1.2. Tỷ lệ dữ liệu thiếu



Nhận xét:

Có 14 trong tổng số 34 cột chứa dữ liệu thiếu. Trong đó, Upfront_charges có tỷ lệ thiếu cao nhất (26,66%), tiếp theo là Interest_rate_spread (24,64%) và rate_of_interest (24,51%).

Các cột dtir1, property_value, LTV và income cũng có tỷ lệ thiếu đáng chú ý, từ 6,15% đến 16,22%. Những cột còn lại thiếu dưới 2,5%.

Đáng chú ý, tỷ lệ thiếu của Interest_rate_spread bằng đúng tỷ lệ Status = 1 (24,64%). Ngoài ra, property_value và LTV có cùng số lượng giá trị thiếu. Những điểm này sẽ được kiểm tra kỹ hơn ở Giai đoạn 2.

1.3. Dữ liệu trùng lặp

Nhận xét: Không phát hiện bản ghi trùng lặp hoặc mã ID bị trùng, kể cả khi kiểm tra dữ liệu không có cột ID. Tuy nhiên, do không có thông tin định danh người vay nên chưa thể xác định một người có nhiều khoản vay trong bộ dữ liệu hay không.

1.4. Các giá trị phân loại

Nhận xét:

- Cột Security_Type có giá trị Indriect bị sai chính tả, còn Region có cách viết hoa không thống nhất giữa các khu vực. Những lỗi này cần được sửa ở Giai đoạn 2.
- Một số thuộc tính sử dụng mã viết tắt như type1, p1, l1 và cf. Do chưa có thông tin giải thích đầy đủ nên các mã này được giữ nguyên.
- Cột Gender có giá trị Sex Not Available, thể hiện trường hợp không có thông tin giới tính. Giá trị này khác với NaN nên không cần thay thế.

1.5. Data Dictionary (34 thuộc tính)

Bảng dưới đây trình bày tên, kiểu dữ liệu và ý nghĩa của 34 thuộc tính trong bộ dữ liệu Loan Default. Một số thuộc tính sử dụng mã viết tắt chưa được Kaggle giải thích rõ nên được giữ nguyên theo dữ liệu gốc.

Các biến chính được sử dụng trong phân tích:

- **Biến mục tiêu:** Status.
- **Thông tin tài chính:** income, Credit_Score, dtir1.
- **Đặc điểm khoản vay:** loan_amount, loan_type, Neg_ammortization, lump_sum_payment.
- **Thông tin tài sản:** property_value, LTV.
- **Thông tin người vay và khu vực:** age, Gender, Region.

Ngoài ra, các biến liên quan đến lãi suất và phí sẽ được kiểm tra kỹ hơn do có nhiều giá trị thiếu.

1.6. Kiểm tra tính nhất quán giữa các cột

Phần này kiểm tra xem các cột có chứa thông tin trùng nhau hoặc có giá trị không nhất quán hay không.

Nhận xét:

- LTV gần như bằng chính xác loan_amount / property_value × 100, với sai lệch rất nhỏ. Hai cột LTV và property_value cũng có 15.098 giá trị thiếu.
- loan_type = type2 luôn đi cùng business_or_commercial = b/c, với 20.762 hồ sơ. Điều này cho thấy hai thuộc tính có liên hệ chặt chẽ với nhau.
- Các giá trị mh, land và Indriect xuất hiện trên cùng 33 dòng dữ liệu.
- age và submission_of_application đều thiếu thông tin trên cùng 200 dòng.
- Tất cả giá trị loan_amount đều kết thúc bằng 6.500, property_value kết thúc bằng 8.000 và income đều chia hết cho 60. Điều này cho thấy dữ liệu có thể đã được làm tròn hoặc xử lý trước khi công bố.

Nhìn chung, một số cột chứa thông tin trùng lặp hoặc liên quan chặt chẽ với nhau. Đây là điều cần lưu ý khi phân tích các thuộc tính ở những giai đoạn tiếp theo.

Giai đoạn 2. Tiền xử lý và làm sạch dữ liệu

Các bước làm sạch được thực hiện trên bản sao df_clean để giữ nguyên dữ liệu gốc df.

Trong quá trình xử lý, những giá trị bị thiếu hoặc bất thường sẽ được xem xét trước khi quyết định thay thế hay giữ nguyên. Điều này giúp hạn chế việc làm thay đổi thông tin ban đầu của bộ dữ liệu.

2.1. Sửa lỗi định dạng

Trước khi phân tích sâu, nhóm tiến hành rà soát các bản ghi trùng lặp (toàn bộ dòng hoặc trùng mã định danh ID) và chuẩn hóa các thuộc tính phân loại bị lỗi chính tả hoặc không đồng nhất kiểu chữ hoa/thường.

Nhận xét:

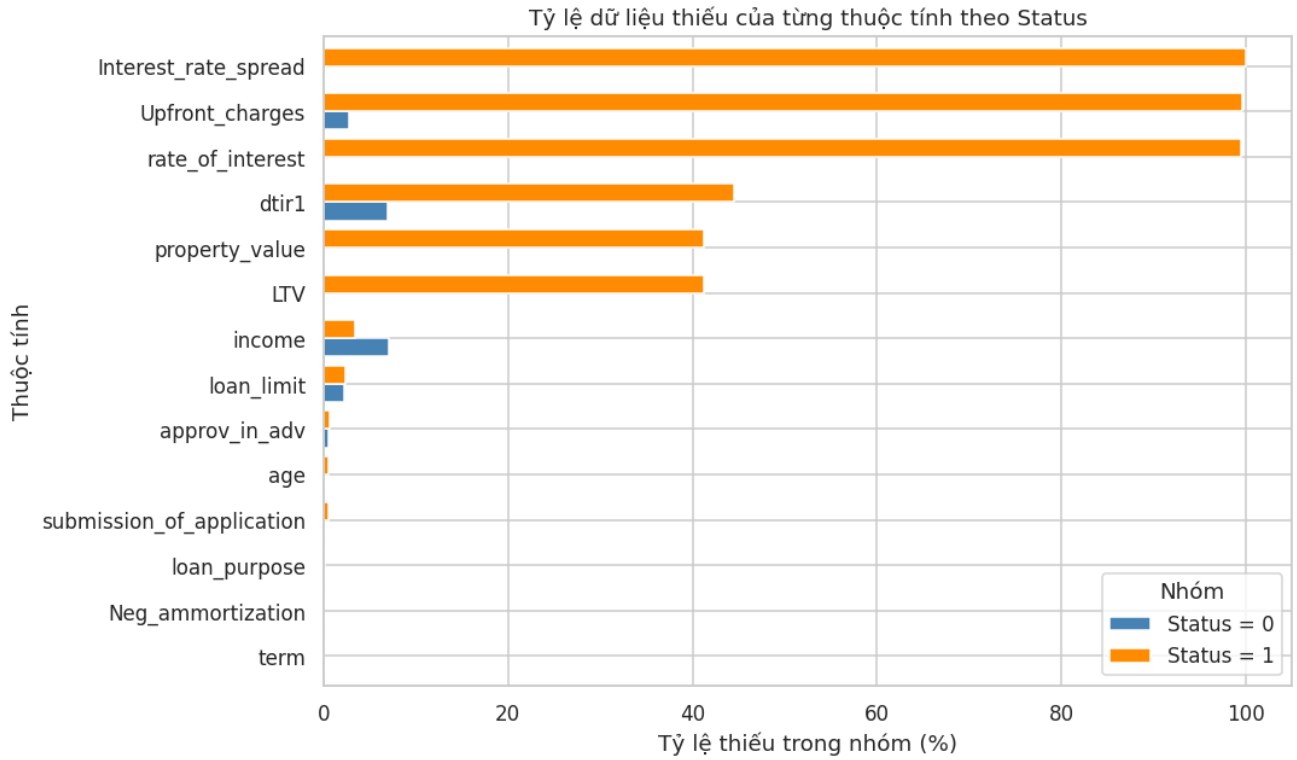
- **Về dữ liệu trùng lặp:** Tập dữ liệu không có dòng nào bị trùng lặp hoàn toàn (0 dòng) và cột định danh ID cũng là duy nhất trên toàn bộ 148.670 quan sát, do đó không cần thực hiện lệnh xóa trùng lặp (drop_duplicates).
- **Về sửa lỗi định dạng:** Đã sửa lỗi chính tả nhập liệu Indriect thành Indirect (33 dòng) trong cột Security_Type và chuẩn hóa quy tắc viết hoa chữ cái đầu (.str.title()) cho cột Region (south South, central Central).
- **Lý do kỹ thuật:** Trong Python, chuỗi ký tự phân biệt chữ hoa/thường và ký tự gõ sai. Nếu không chuẩn hóa, chương trình sẽ hiểu nhầm thành các danh mục khác nhau (*false categories*), gây sai lệch khi lập bảng tần số, kiểm định (Chi-square) hoặc sinh thêm cột dư thừa khi áp dụng One-Hot Encoding.

Nhận xét: Đã sửa lỗi chính tả Indriect thành Indirect và thống nhất cách viết tên các khu vực trong Region. Việc chỉnh sửa không làm thay đổi số lượng dữ liệu của từng nhóm, giúp dữ liệu nhất quán hơn cho các bước phân tích tiếp theo.

2.2. Kiểm tra dữ liệu thiếu theo Status

Phần này kiểm tra xem tỷ lệ dữ liệu thiếu có khác nhau giữa hai nhóm Status = 0 và Status = 1 hay không.

Nếu sự khác biệt lớn, việc xóa hoặc thay thế các giá trị thiếu có thể ảnh hưởng đến kết quả phân tích. Vì vậy, cần kiểm tra trước khi lựa chọn cách xử lý.



Nhận xét:

- Interest_rate_spread thiếu ở toàn bộ nhóm Status = 1 (100%), trong khi nhóm Status = 0 không thiếu giá trị nào. Tương tự, rate_of_interest và Upfront_charges cũng có tỷ lệ thiếu rất cao ở nhóm Status = 1, lần lượt là 99,45% và 99,58%.
- property_value và LTV đều thiếu 41,20% ở nhóm Status = 1, trong khi nhóm Status = 0 chỉ có 2 dòng bị thiếu. dtir1 cũng có sự chênh lệch đáng kể giữa hai nhóm (44,52% so với 6,97%).
- Ngược lại, income thiếu nhiều hơn ở nhóm Status = 0 (7,06%) so với nhóm Status = 1 (3,38%).
- Các cột còn lại có tỷ lệ thiếu tương đối thấp, phần lớn dưới 1%.

Kết luận: Dữ liệu thiếu có sự khác biệt rõ rệt giữa hai nhóm Status, đặc biệt ở các thuộc tính liên quan đến lãi suất và tài sản. Vì vậy, việc xóa các dòng bị thiếu hoặc tự động điền giá trị có thể làm sai lệch kết quả phân tích. Cần cân nhắc cách xử lý riêng cho từng thuộc tính.

Nhận xét:

- Interest_rate_spread thiếu toàn bộ 36.639 dòng thuộc nhóm Status = 1, trong khi không có dòng nào thuộc nhóm Status = 0 bị thiếu. Điều này cho thấy việc thiếu dữ liệu ở cột này có liên hệ trực tiếp với Status.
- Nếu sử dụng dropna() để xóa tất cả các dòng có giá trị thiếu, dữ liệu chỉ còn 98.187 dòng và tất cả đều thuộc nhóm Status = 0. Khi đó, không thể tiếp tục so sánh hai nhóm.
- Một số thuộc tính thường bị thiếu cùng nhau. Chẳng hạn, có 20.329 dòng thiếu đồng thời rate_of_interest, Interest_rate_spread và Upfront_charges, nhưng vẫn có thông tin property_value và dtir1.
- LTV và dtir1 cũng thiếu nhiều ở nhóm Status = 1, nên các phép so sánh chỉ sử dụng giá trị có sẵn có thể không phản ánh đầy đủ đặc điểm của nhóm này.

Kết luận: Không nên xóa toàn bộ các dòng có NaN hoặc tự động điền giá trị thiếu. Đặc biệt, việc thiếu Interest_rate_spread có thể khiến mô hình dự đoán dựa vào dấu hiệu thiếu dữ liệu thay vì những đặc điểm thực sự của khoản vay.

2.3. Quyết định xử lý dữ liệu thiếu

- Dựa trên kết quả kiểm tra ở mục 2.2, dữ liệu thiếu được xử lý như sau:
- **Các biến phân loại (**loan_limit**,** approv_in_adv**,** loan_purpose**,** Neg_ammortization**,** age**,** submission_of_application**) Điền nhãn** 'Unknown' **thay vì dùng** Mode**.**

- **age và submission_of_application**: Điền Unknown vì cả 200 dòng thiếu đều thuộc nhóm Status = 1. Riêng nhóm tuổi Unknown sẽ không được đưa vào kiểm định về tuổi.

- **term**: Điền Mode = 360 vì đây là giá trị xuất hiện nhiều nhất và chỉ có 41 dòng bị thiếu.
- **income**: Giữ nguyên NaN vì tỷ lệ thiếu khác nhau giữa hai nhóm Status. Việc điền Median có thể làm thay đổi phân phối dữ liệu.
- **rate_of_interest, Interest_rate_spread và Upfront_charges**: Giữ nguyên NaN vì dữ liệu thiếu tập trung chủ yếu ở nhóm Status = 1. Những cột này không được sử dụng để so sánh trực tiếp hai nhóm trong phân tích hiện tại.
- **property_value, LTV và dtir1**: Giữ nguyên NaN vì tỷ lệ thiếu khá cao, đặc biệt ở nhóm Status = 1. Khi phân tích, nhóm thiếu dữ liệu sẽ được xem xét riêng.
- **Vì sao xét Median (5.760,0) thay vì Mean (6.957,34):** Với độ lệch phải cực lớn (Skewness=17,31) và giá trị cực đại lên tới 578.580,0, giá trị trung bình (Mean) bị kéo cao hơn trung vị tới gần 1.200 đơn vị. Nếu bắt buộc phải điền giá trị thiếu cho biến liên tục có ngoại lệ như income, Median luôn được ưu tiên để tránh làm lệch tâm phân phối.
- **Vì sao quyết định giữ nguyên NaN:** Kết quả thực nghiệm cho thấy khi điền 9.150 giá trị thiếu bằng Median chung (5.760), độ lệch chuẩn giảm từ 6.496,59 xuống 6.300,07 (làm co hẹp phương sai tự nhiên). Nghiêm trọng hơn, trung vị của từng nhóm bị kéo về gần nhau (Status = 0 giảm từ 6.000 xuống 5.760, còn Status = 1 tăng từ 4.860 lên 5.040), làm độ lớn hiệu ứng (*effect size* Rank-biserial r) suy giảm từ 0,1846 xuống 0,1806. Để bảo toàn sự khác biệt thực tế giữa hai nhóm, nhóm giữ nguyên NaN trên df_clean.

Xử lý giá trị thiếu trong cột income

Cột income có một số giá trị thiếu. Trước khi quyết định có nên điền Median hay không, ta sẽ so sánh dữ liệu trước và sau khi điền để xem phương pháp này ảnh hưởng như thế nào đến kết quả phân tích.

Lưu ý: Việc điền Median chỉ được thực hiện trên một Series riêng (income_imputed) để so sánh, không làm thay đổi df_clean.

Nhận xét: Sau khi điền 9.150 giá trị thiếu bằng Median (5.760), Mean và độ lệch chuẩn của thu nhập đều giảm. Median của từng nhóm Status cũng thay đổi, trong khi effect size giảm nhẹ từ 0,1846 xuống 0,1806.

Điều này cho thấy việc điền Median có thể làm thay đổi kết quả phân tích. Vì vậy, ta giữ nguyên các giá trị NaN trong cột income và chỉ sử dụng những giá trị có sẵn khi phân tích thu nhập.

Nhận xét: Có 1.260 khoản vay có income = 0, trong đó 99,37% thuộc nhóm Status = 1. Phần lớn các khoản vay này có credit_type = EQUI (912 khoản).

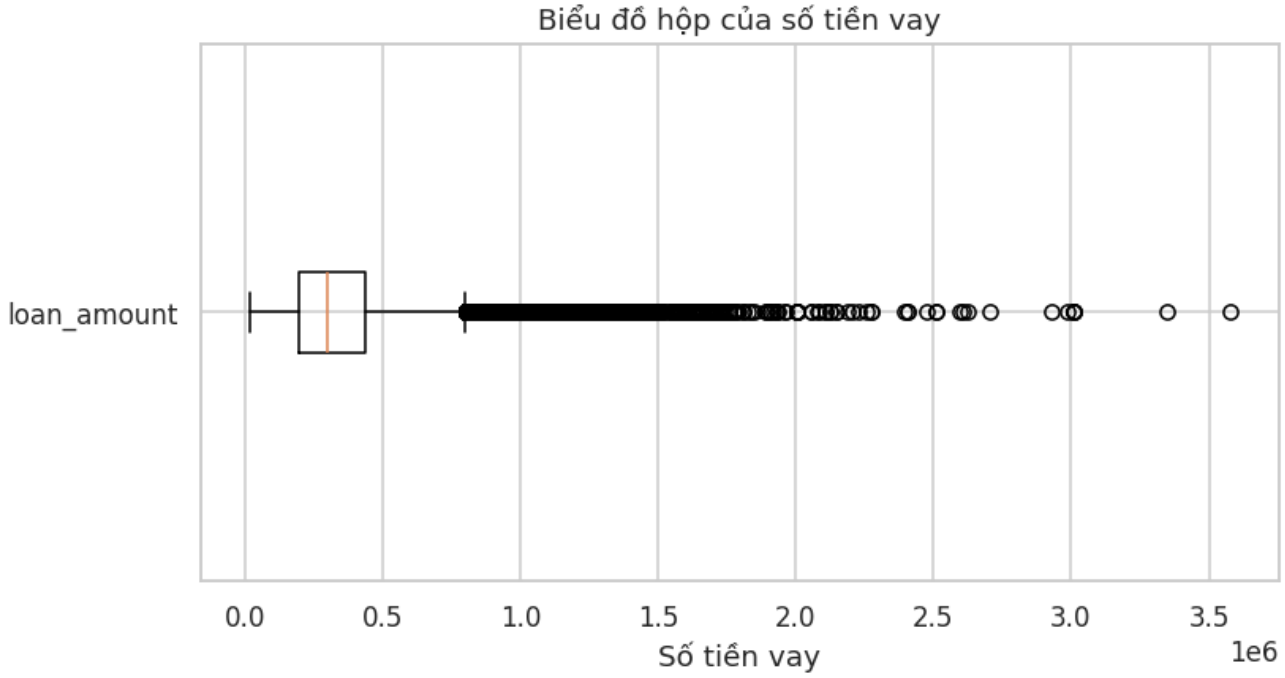
Chưa thể xác định thu nhập bằng 0 là giá trị thực tế hay cách ghi nhận dữ liệu thiếu. Vì vậy, ta giữ nguyên các quan sát này và sẽ kiểm tra xem việc loại chúng khỏi phân tích có làm thay đổi kết quả hay không ở mục 3.5.

2.4. Phát hiện và đánh giá giá trị ngoại lệ (Outliers)

Sử dụng thống kê mô tả, quy tắc IQR (1,5 × IQR) và biểu đồ hộp để phát hiện các giá trị ngoại lệ.

Tuy nhiên, không phải giá trị ngoại lệ nào cũng là dữ liệu sai. Đặc biệt, với những biến có phân phối lệch phải, các giá trị lớn vẫn có thể hợp lệ. Vì vậy, cần xem xét trước khi quyết định có loại bỏ hay không.

2.4.1. Số tiền vay (loan_amount)

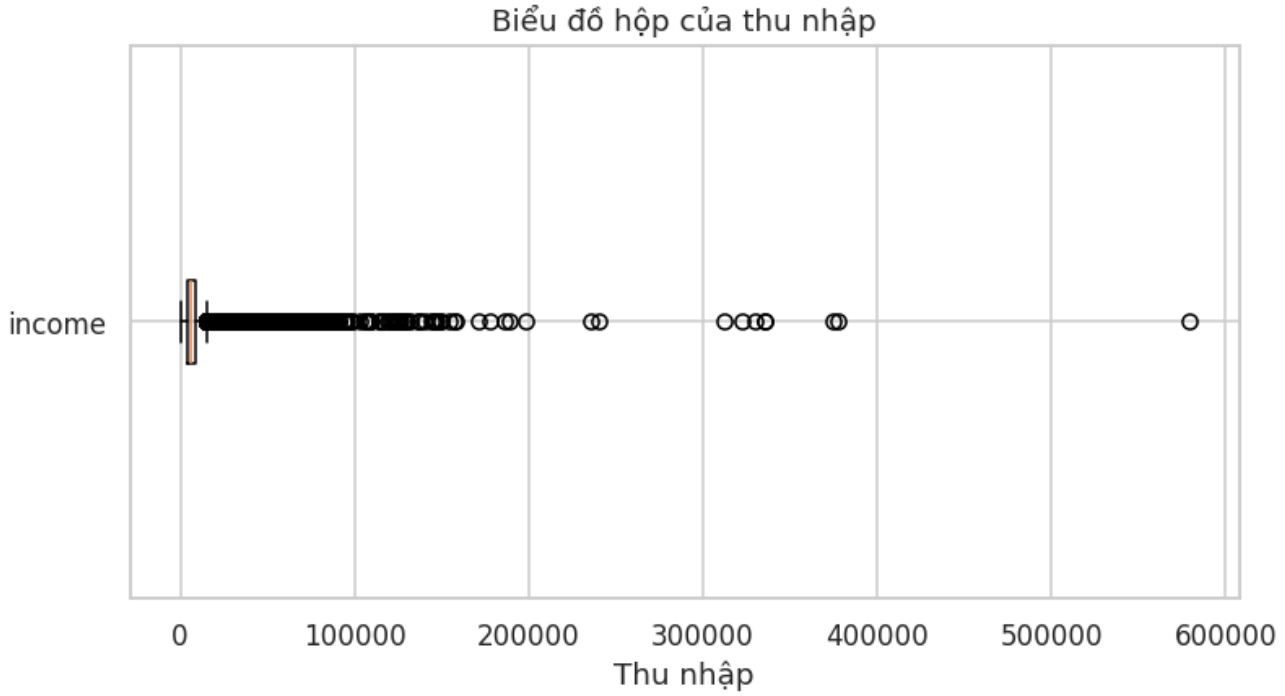


Nhận xét: Có 1.895 khoản vay (1,27%) vượt ngưỡng trên 796.500, cho thấy phân phối số tiền vay có đuôi phải kéo dài.

Trong 10 khoản vay lớn nhất, những khoản có đủ thông tin tài sản đều có LTV khoảng 52-86%, cho thấy số tiền vay tương đối phù hợp với giá trị tài sản. Tuy nhiên, một số khoản còn thiếu thông tin nên chưa thể kết luận tất cả ngoại lệ đều hợp lệ.

Quyết định: Giữ nguyên các khoản vay này vì chưa có đủ bằng chứng cho thấy chúng là dữ liệu sai. Khi so sánh số tiền vay giữa các nhóm, sử dụng kiểm định Mann-Whitney để hạn chế ảnh hưởng của các giá trị quá lớn.

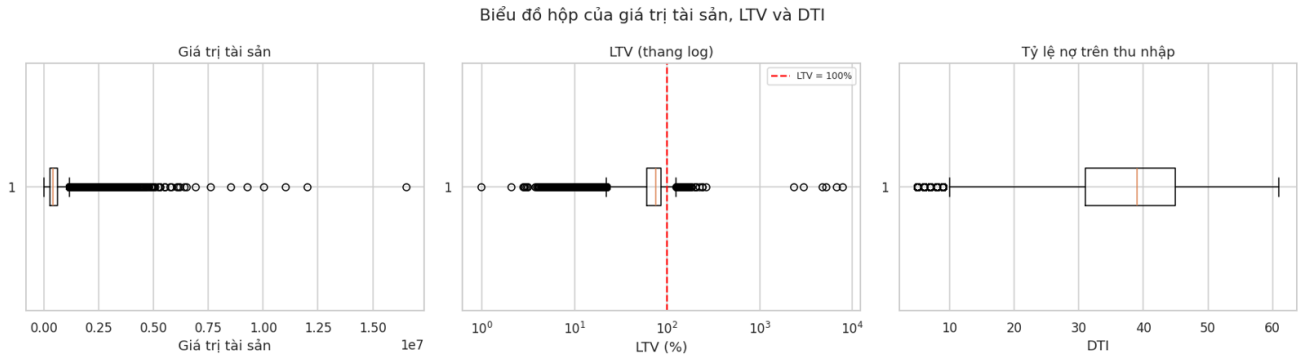
2.4.2. Thu nhập (income)



Nhận xét: Có 6.546 giá trị thu nhập (4,69% số quan sát có thu nhập) vượt ngưỡng trên 15.720. Giá trị lớn nhất là 578.580, cao gấp khoảng 100 lần Median (5.760), cho thấy phân phối thu nhập lệch phải rất mạnh.

Quyết định: Giữ nguyên các giá trị ngoại lệ vì chưa có đủ bằng chứng cho thấy chúng là dữ liệu sai. Khi phân tích, ưu tiên sử dụng Median và kiểm định Mann–Whitney để hạn chế ảnh hưởng của các giá trị quá lớn.

2.4.3. Giá trị tài sản (property_value), LTV và DTI



Nhận xét:

- property_value: Có 5.266 giá trị (3,94%) vượt ngưỡng trên IQR. Phân phối lệch phải, tương tự số tiền vay. Chưa có đủ bằng chứng để xem các giá trị lớn này là dữ liệu sai nên tạm thời giữ nguyên.
- dtir1: Có 2.013 giá trị (1,62%) nằm dưới ngưỡng IQR. Các giá trị này vẫn nằm trong phạm vi dữ liệu từ 5 đến 61 nên được giữ lại.
- LTV: Có 1.882 giá trị ngoại lệ (1,41%). Đặc biệt, giá trị lớn nhất lên đến 7.831,25%, cao bất thường và cần được kiểm tra kỹ hơn ở phần tiếp theo.

2.4.4. Điều tra các giá trị LTV cực lớn

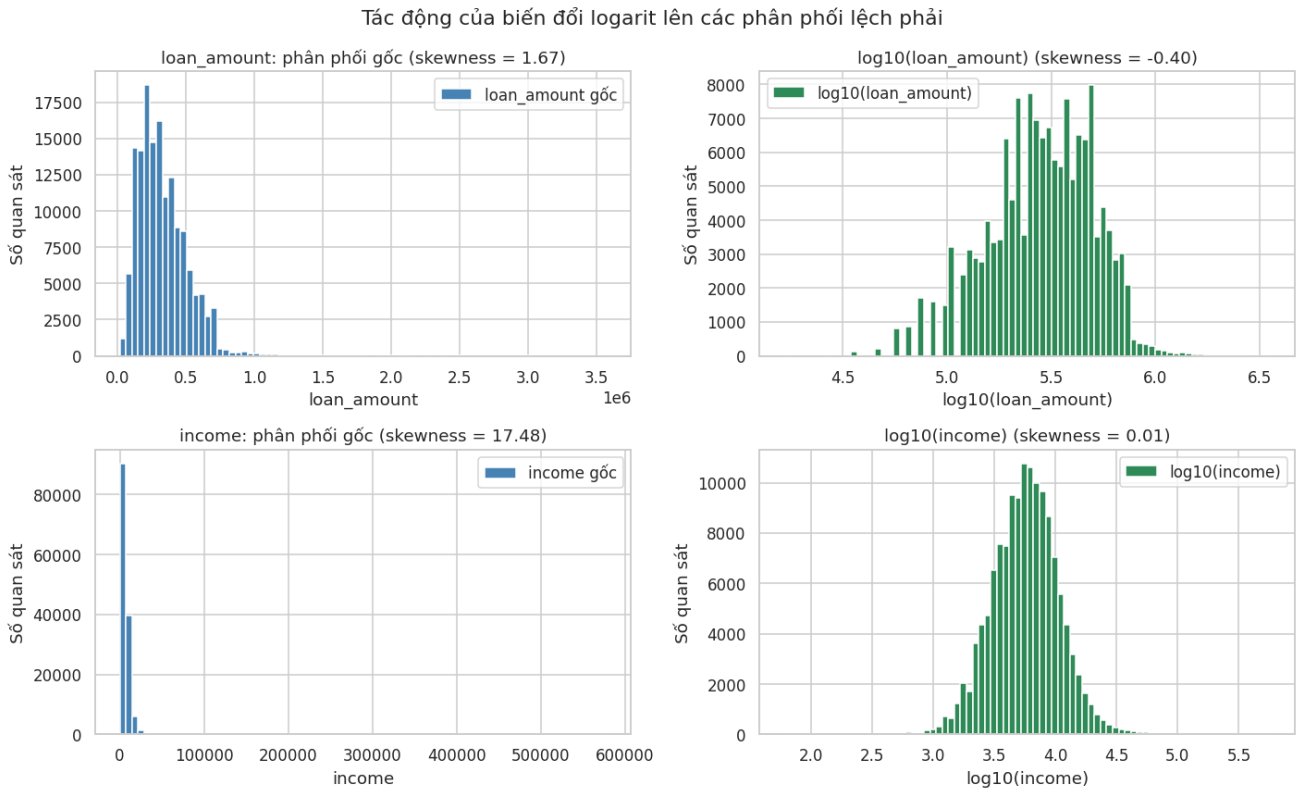
Nhận xét và quyết định xử lý LTV

Có 6 khoản vay có LTV đặc biệt cao, từ 2.331% đến 7.831%. Cả 6 đều có property_value = 8.000, trong khi số tiền vay lớn hơn rất nhiều. Giá trị LTV cao nhất còn lại chỉ là 263,54%, cho thấy 6 khoản vay này khác biệt rõ rệt so với phần còn lại của dữ liệu.

Khi loại tạm thời 6 dòng này để kiểm tra, độ lệch chuẩn của LTV giảm từ 39,97 xuống 18,94 và Skewness giảm từ 120,62 xuống −0,63. Trong khi đó, Mean chỉ thay đổi nhẹ và Median gần như không đổi.

Điều này cho thấy 6 giá trị cực lớn ảnh hưởng mạnh đến phân phối LTV, đặc biệt là độ lệch chuẩn và Skewness. Tuy nhiên, chưa thể xác định đây có phải lỗi dữ liệu hay không.

Quyết định: Giữ nguyên dữ liệu và đánh dấu 6 khoản vay nghi ngờ để theo dõi. Trong các phân tích tiếp theo, ưu tiên sử dụng nhóm LTV, kiểm định Mann–Whitney và hệ số tương quan Spearman để hạn chế ảnh hưởng của các giá trị cực lớn.



Nhận xét: Sau khi biến đổi log10, phân phối của loan_amount và income trở nên cân đối hơn. Skewness của loan_amount giảm từ 1,67 xuống −0,40, còn income giảm từ 17,48 xuống 0,01.

Biến đổi log giúp quan sát dữ liệu rõ hơn khi có nhiều giá trị lớn. Tuy nhiên, các cột gốc vẫn được giữ nguyên để dễ diễn giải kết quả phân tích.

Lưu ý: Phép biến đổi log10 chỉ áp dụng cho các giá trị lớn hơn 0. Vì vậy, 1.260 quan sát có income = 0 không xuất hiện trong biểu đồ này.

2.5. Encoding và Scaling

Dựa trên kết quả khảo sát số lượng nhóm (category_cardinality) và bảng phân phối ngoại lệ/độ lệch (outlier_summary) ở mục 2.3 – 2.4, nhóm giải trình việc lựa chọn kỹ thuật **Encoding** và **Scaling** phù hợp với đặc trưng phân phối của từng thuộc tính (được thực thi minh họa trên bản sao df_transformed) như sau:

A. Giải trình lựa chọn phép Mã hóa (Encoding):

- **Ordinal Encoding (Mã hóa thứ bậc) cho thuộc tính** age **(8 nhóm):**
  - *Đặc điểm dữ liệu:* Gồm các khoảng tuổi có thứ tự tăng dần tự nhiên (<25 < 25-34 < 35-44 < 45-54 < 55-64 < 65-74 < >74) và nhóm thiếu thông tin (Unknown).
  - *Lý do lựa chọn:* Sử dụng Ordinal Encoding giúp bảo toàn thông tin về thứ tự và khoảng cách độ tuổi. Nếu dùng One-Hot Encoding sẽ đánh mất tính thứ bậc tự nhiên này và sinh thêm 7 cột nhị phân không cần thiết.
- **One-Hot Encoding cho 20 thuộc tính phân loại còn lại (**Region, loan_purpose, credit_type**,** loan_limit**,...):**
  - *Đặc điểm dữ liệu:* Là các biến phân loại **danh nghĩa (Nominal)**, không có quan hệ lớn nhỏ hay hơn kém giữa các nhãn. Đồng thời, bảng thống kê category_cardinality bên dưới chứng minh cả 20 biến này đều có **số lượng nhóm rất nhỏ (*low cardinality*, chỉ từ 2 đến 5 nhóm)**.
  - *Lý do lựa chọn:* Chọn **One-Hot Encoding** (drop_first=True để tránh đa cộng tuyến) thay vì **Label Encoding**, vì Label Encoding gán các số nguyên 0,1,2,3... sẽ khiến thuật toán hiểu nhầm có thứ tự ưu tiên giữa các vùng địa lý (Region) hay mục đích vay (loan_purpose). Do số nhóm chỉ từ 2-5,

One-Hot Encoding hoàn toàn không gây ra hiện tượng bùng nổ số chiều (*curse of dimensionality*).

B. Giải trình lựa chọn phép Chuẩn hóa (Scaling) theo phân phối:

- **Tại sao không dùng** MinMaxScaler **hay** StandardScaler **trực tiếp cho** income, loan_amount, property_value, LTV**?**
  - *Minh chứng từ phân phối mục 2.4:* Cả 4 biến này đều có phân phối lệch phải rất mạnh (Skewness lần lượt là 17,31; 1,67; 4,59 và 120,62) kèm theo tỷ lệ ngoại lệ từ 1,27% đến 4,69% được giữ lại (ví dụ income có Max = 578.580 gấp 100 lần Median = 5.760).
  - *Hạn chế của* MinMaxScaler*:* Công thức x'=x-- phụ thuộc hoàn toàn vào và . Khi quá lớn (578.580), hơn 95% quan sát thông thường sẽ bị nén chặt vào một khoảng cực nhỏ sát 0, làm mất khả năng phân biệt giữa các khách hàng.
  - *Hạn chế của* StandardScaler *trực tiếp:* Công thức z=x- sử dụng trung bình () và độ lệch chuẩn (). Như đã chứng minh ở mục 2.4.4, chỉ 6 dòng ngoại lệ của LTV đã làm tăng gấp đôi từ 18,94 lên 39,97, khiến phép chuẩn hóa Z-score bị bóp méo.
- **Giải pháp lựa chọn cho từng nhóm phân phối:z**
  1. **Với** loan_amount**,** income**,** property_value**,** LTV **(Phân phối lệch phải mạnh, có ngoại lệ cực đại) Chọn** RobustScaler **(hoặc kết hợp biến đổi** Log10 **+** StandardScaler**):**
     RobustScaler chuẩn hóa theo công thức 

     (trong đó IQR=Q3-Q1). Vì Median và IQR hoàn toàn không bị ảnh hưởng bởi các giá trị cực trị ở hai đầu (như đã chứng minh ở bảng độ nhạy LTV) đồng thời xử lý được cả các quan sát income = 0, đây là kỹ thuật chuẩn hóa bền vững nhất cho phân phối thực tế của tập dữ liệu.
  2. **Với** dtir1 **(Phân phối gần đối xứng Skewness = -0,55$, miền giá trị [5,61] không có ngoại lệ cực đại) Chọn** StandardScaler**:**
     Do phân phối của dtir1 cân đối và không bị kéo lệch bởi ngoại lệ phía trên, Mean và Std phản ánh chính xác tâm và độ phân tán của dữ liệu, hoàn toàn phù hợp với StandardScaler.

Lưu ý : Trong bài phân tích này, **không cần áp dụng Encoding và Scaling** vì mục tiêu là khám phá dữ liệu và kiểm định thống kê, không phải xây dựng mô hình dự đoán.

- **Encoding:** Các biến phân loại như `Region`, `loan_type` và `credit_type` có thể được sử dụng trực tiếp trong bảng tần số và kiểm định Chi-square mà không cần chuyển thành số. Với `age`, chỉ cần sắp xếp các nhóm tuổi theo đúng thứ tự khi trực quan hóa.
- **Scaling:** Các kiểm định Mann–Whitney và tương quan Spearman dựa trên thứ hạng nên không cần chuẩn hóa thang đo. Tương quan Pearson cũng không thay đổi khi áp dụng phép chuẩn hóa tuyến tính với hệ số dương.

Hướng mở rộng: Nếu xây dựng mô hình dự đoán trong tương lai, có thể cần Encoding cho các biến phân loại và Scaling cho một số biến số, tùy thuộc vào thuật toán. Các bước xử lý phải được học từ tập huấn luyện để tránh rò rỉ dữ liệu (*data leakage*).

Kết luận: Giữ nguyên các biến sau bước làm sạch và sử dụng trực tiếp cho Giai đoạn 3.

Nhận xét: Các biến phân loại trong bộ dữ liệu đều có ít nhóm, nhiều nhất là age với 8 nhóm (bao gồm Unknown).

Nếu xây dựng mô hình dự đoán trong tương lai, One-hot Encoding có thể là lựa chọn phù hợp cho các biến phân loại không có thứ tự. Tuy nhiên, trong bài phân tích hiện tại, chưa cần thực hiện bước mã hóa này.

2.6. Kiểm tra kết quả làm sạch

Tổng kết Giai đoạn 2:

- **Bảo toàn kích thước và tính toàn vẹn dữ liệu:** Sau khi làm sạch, df_clean giữ nguyên **148.670 dòng và 34 cột** (không phát hiện bản ghi hay ID trùng lặp). Hai lỗi định dạng chuỗi ở Security_Type (Indriect Indirect) và Region (chuẩn hóa viết hoa .str.title()) đã được khắc phục hoàn toàn mà không làm ảnh hưởng đến dữ liệu gốc df.
- **Xử lý dữ liệu khuyết thiếu có chọn lọc:** 7 thuộc tính có tỷ lệ thiếu nhỏ được xử lý bằng cách gán nhãn 'Unknown' (cho 6 biến phân loại nhằm giữ lại tín hiệu thiếu hồ sơ) hoặc điền Mode = 360.0 (cho biến rời rạc term). 7 thuộc tính định lượng còn lại được giữ nguyên NaN có chủ đích do dữ liệu khuyết thiếu gắn liền với nhóm Status = 1 (việc thử nghiệm điền Median cho income dù tốt hơn Mean trên phân phối lệch phải Skewness = 17,31 nhưng vẫn làm giảm phương sai và làm yếu độ lớn hiệu ứng Rank-biserial r).
- **Đánh giá ngoại lệ và chuẩn bị biến đổi đặc trưng:** Các ngoại lệ hợp lệ về quy mô khoản vay/thu nhập được giữ lại, riêng 6 dòng nghi ngờ lỗi dữ liệu có LTV > 1000% (property_value = 8.000) được xác định qua biến ltv_suspect để kiểm soát độ nhạy. Nhóm cũng đã thiết lập và giải trình đầy đủ phương án **Ordinal Encoding** (cho age), **One-Hot Encoding** (cho 20 biến danh nghĩa ít nhóm), **RobustScaler / 10** (cho các biến lệch phải có ngoại lệ) và **StandardScaler** (cho biến đối xứng dtir1) trên bản sao df_transformed, trong khi giữ nguyên đơn vị gốc trên df_clean để phục vụ trực quan hóa và kiểm định thống kê ở Giai đoạn 3.

Giai đoạn 3. Phân tích, kiểm định giả thuyết và trực quan hóa

3.0. Phương pháp phân tích

Các kiểm định được lựa chọn dựa trên loại biến và đặc điểm phân phối đã xem xét ở Giai đoạn 2.

Loại biến so với Status	Kiểm định	Effect size
Biến phân loại	Chi-square	Cramér's V
Biến số hoặc thứ bậc	Mann–Whitney U (hai phía)	Rank-biserial r

Chi-square: Dùng để kiểm tra mối liên hệ giữa hai biến phân loại. Cần chú ý tính độc lập của các quan sát và tần số kỳ vọng trong bảng. Với bảng 2×2, chi2_contingency mặc định áp dụng hiệu chỉnh Yates.

Mann–Whitney U: Dùng để so sánh phân phối thứ hạng giữa hai nhóm Status. Kiểm định không yêu cầu dữ liệu có phân phối chuẩn, phù hợp với các biến tài chính có phân phối lệch và nhiều giá trị ngoại lệ. Tuy nhiên, kết quả không tự động có nghĩa là trung vị của hai nhóm khác nhau.

Đánh giá kết quả: Ngoài p-value, bài phân tích sử dụng effect size để xem xét mức độ liên hệ hoặc khác biệt. Với cỡ mẫu lớn, những khác biệt nhỏ cũng có thể đạt ý nghĩa thống kê, nên không chỉ dựa vào p-value để đưa ra nhận xét.

Do thực hiện nhiều kiểm định, bảng tổng hợp ở mục 3.12 sẽ áp dụng hiệu chỉnh Bonferroni.

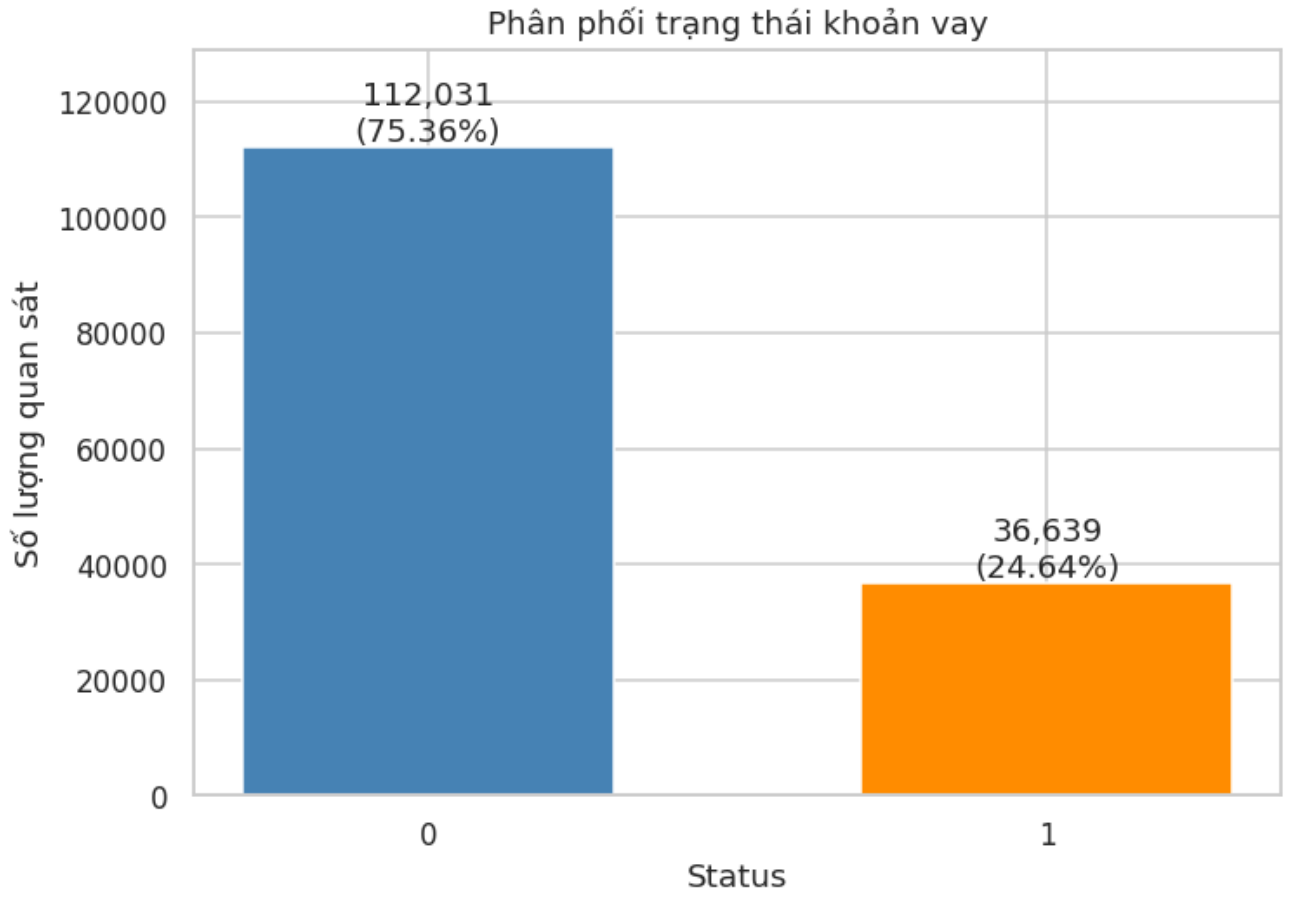
Giới hạn: Dữ liệu mang tính quan sát, vì vậy các kết quả chỉ phản ánh mối liên hệ, không chứng minh quan hệ nhân quả.

Xử lý dữ liệu thiếu: Nhóm Unknown của age được loại khỏi kiểm định tuổi vì cả 200 dòng đều có Status = 1. Với income, LTV và dtir1, kiểm định Mann–Whitney chỉ sử dụng các dòng có giá trị tương ứng. Riêng LTV và dtir1, tình trạng thiếu dữ liệu cũng được phân tích riêng để đánh giá khả năng ảnh hưởng đến kết quả.

3.0.1. Phân phối biến mục tiêu Status

	Status	count
0	0	112031
1	1	36639

	Status	Tỷ lệ (%)
0	0	75.36
1	1	24.64



Nhận xét: Status = 0 chiếm **75,36%** (112.031 khoản vay), trong khi Status = 1 chiếm **24,64%** (36.639 khoản vay), tương đương tỷ lệ khoảng 3:1. Dữ liệu có sự mất cân bằng giữa hai nhóm.

Trong các phân tích tiếp theo, tỷ lệ chung **24,64%** của Status = 1 sẽ được sử dụng làm mốc tham chiếu để so sánh tỷ lệ giữa các nhóm khoản vay.

3.1. Nhóm tuổi và Status

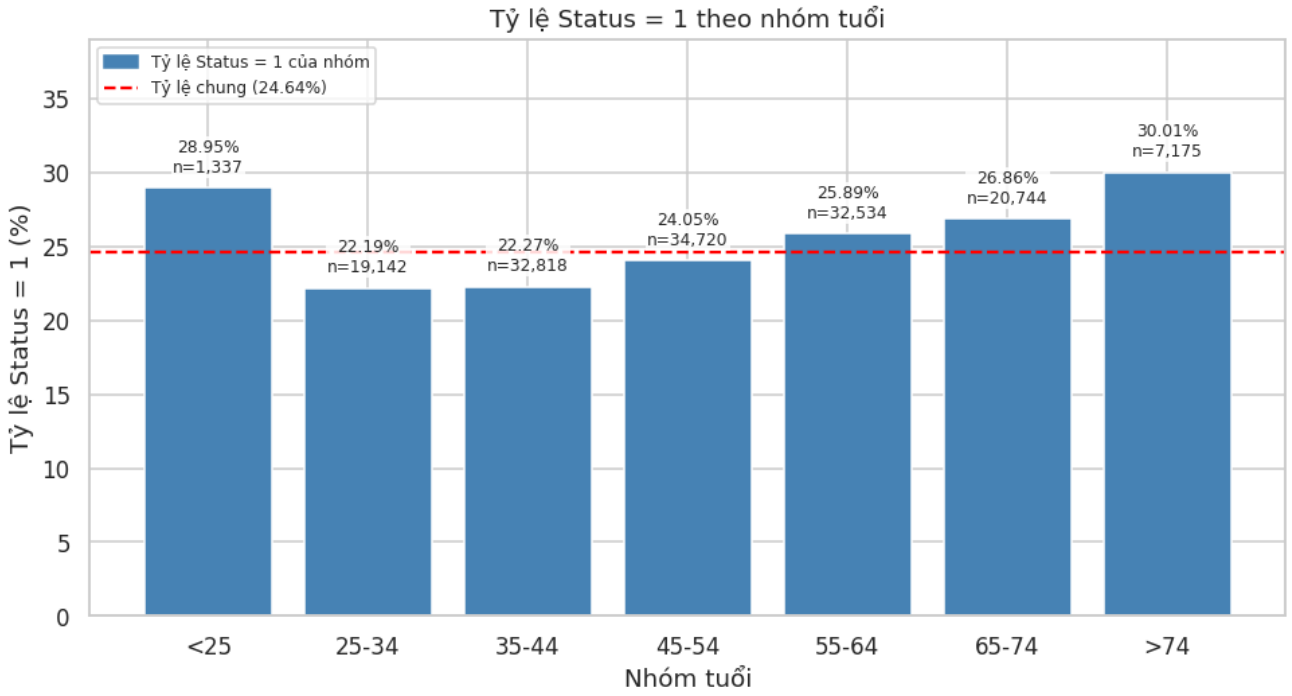
Giả thuyết H_0: Nhóm tuổi và Status độc lập với nhau.

- **Giả thuyết H_1:** Có mối liên hệ giữa nhóm tuổi và Status.
- **Lý do chọn biến:** Tuổi là một đặc điểm nhân khẩu học có thể liên quan đến tình trạng khoản vay. Phân tích này nhằm tìm hiểu sự khác biệt giữa các nhóm tuổi, không nhằm đề xuất sử dụng tuổi làm tiêu chí xét duyệt khoản vay.

Status	Nhóm tuổi	0	1
0	<25	950	387
1	25-34	14894	4248
2	35-44	25509	7309
3	45-54	26371	8349
4	55-64	24112	8422
5	65-74	15173	5571
6	>74	5022	2153
7	Unknown	0	200

Status	Nhóm tuổi	0	1
0	<25	71.05	28.95

1	25-34	77.81	22.19
2	35-44	77.73	22.27
3	45-54	75.95	24.05
4	55-64	74.11	25.89
5	65-74	73.14	26.86
6	>74	69.99	30.01
7	Unknown	0.00	100.00



Nhận xét:

- **Phân phối:** Tỷ lệ Status = 1 tăng dần từ **22,19%** ở nhóm 25–34 tuổi lên **30,01%** ở nhóm trên 74 tuổi, chênh lệch 7,82 điểm phần trăm. Riêng nhóm dưới 25 tuổi có tỷ lệ khá cao (28,95%), nhưng số quan sát ít hơn các nhóm còn lại (1.337).
- **Kiểm định:** Giả định ban đầu: người vay rất trẻ và cao tuổi dễ vỡ nợ hơn. H_0: nhóm tuổi và Status độc lập. Chi-square (bỏ nhóm Unknown): $\chi^2 = 374{,}50$; $p < 0{,}001$ → bác bỏ H_0; Cramér's V = 0,05 (không đáng kể). Mặc dù có ý nghĩa thống kê, mức độ liên hệ thực tế là nhỏ.
- **Giới hạn:** Kết quả chưa xét đến ảnh hưởng của các yếu tố khác như thu nhập hoặc đặc điểm khoản vay. Vì vậy, không thể kết luận tuổi trực tiếp ảnh hưởng đến tình trạng khoản vay hoặc sử dụng kết quả này làm căn cứ xét duyệt theo tuổi.
- **Diễn giải:** Thấp nhất ở nhóm 25-34 (22,19%), tăng dần đến 30,01% ở nhóm trên 74; nhóm dưới 25 cũng cao (28,95%), tạo hình chữ U nhẹ.
- **Kết luận:** chênh lệch lớn nhất chỉ khoảng 8 điểm %, tuổi gần như không giúp phân biệt rủi ro.

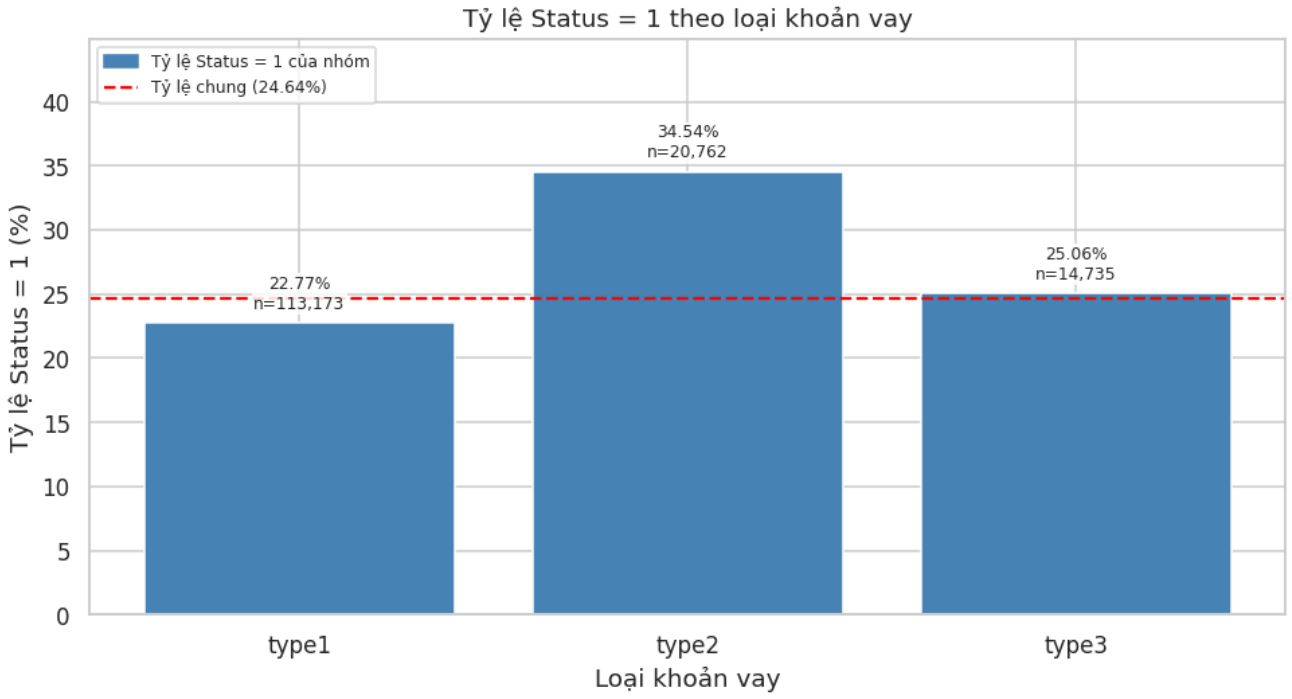
3.2. Loại khoản vay (loan_type) và Status

- **H_0:** loan_type và Status độc lập với nhau.
- **H_1:** Có mối liên hệ giữa loan_type và Status.
- **Lý do chọn biến:** Phân tích nhằm kiểm tra liệu tỷ lệ Status = 1 có khác nhau giữa các loại khoản vay hay không. Ý nghĩa cụ thể của type1, type2 và type3 chưa được xác nhận. Ngoài ra, type2 trùng hoàn toàn với nhóm business_or_commercial = b/c như đã phát hiện ở mục 1.6.

Status	Loại khoản vay	0	1
0	type1	87398	25775
1	type2	13590	7172
2	type3	11043	3692

Status	Loại khoản vay	0	1
0	type1	77.23	22.77

1	type2	65.46	34.54
2	type3	74.94	25.06

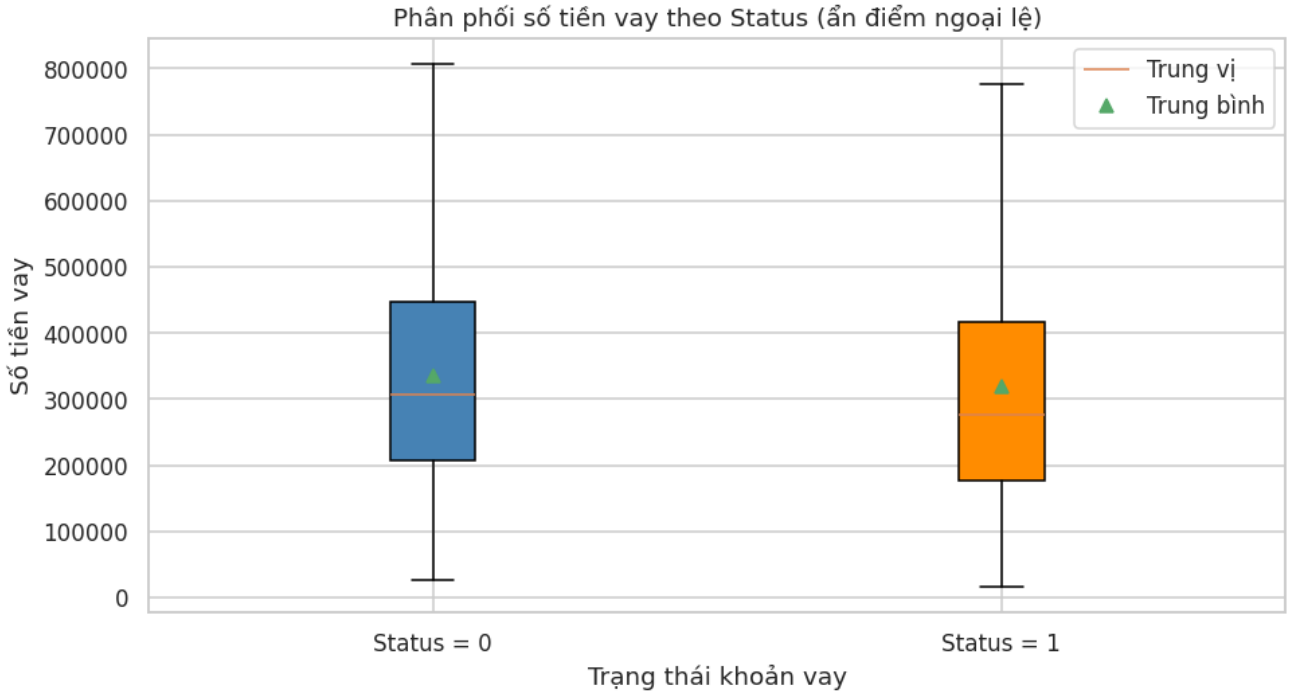


Nhận xét:

- **Phân phối:** type2 có tỷ lệ Status = 1 cao nhất (**34,54%**), cao hơn type1 (22,77%) khoảng **11,77%**, tương đương 1,52 lần. type3 (25,06%) gần với mức chung 24,64%.
- **Kiểm định:** Chi-square cho kết quả $\chi^2 = 1.309,96$, $p < 0,001$, nên bác bỏ H_0. Tần số kỳ vọng nhỏ nhất là 3.631,4, đáp ứng điều kiện áp dụng kiểm định.
- **Mức độ liên hệ:** Cramér's V = **0,0939**, cho thấy mối liên hệ tổng thể yếu giữa loại khoản vay và Status, mặc dù sự khác biệt về tỷ lệ giữa type2 và type1 khá rõ.
- **Diễn giải:** type2 có tỷ lệ vỡ nợ 34,54%, gấp 1,52 lần type1 (22,77%); type3 (25,06%) gần mức chung. Mức liên hệ chung vẫn thấp vì type2 chỉ chiếm khoảng 14% số khoản vay. Nhận định: khoản vay kinh doanh phụ thuộc vào dòng tiền kinh doanh nên rủi ro hơn, cần được thẩm định riêng
- **Kết luận:** khoản vay kinh doanh rủi ro hơn rõ rệt; Cramér's V nhỏ chỉ vì type2 chiếm khoảng 14% số khoản.
- **Ý nghĩa và giới hạn:** type2 trùng hoàn toàn với nhóm business_or_commercial = b/c, nên hai biến không cung cấp thông tin độc lập. Kết quả chưa xét đến các yếu tố khác như số tiền vay hoặc credit_type, đồng thời ý nghĩa cụ thể của các mã loan_type chưa được xác nhận.

3.3. Số tiền vay (loan_amount) và Status

- **H_0:** Phân phối loan_amount giống nhau giữa hai nhóm Status.
- **H_1:** Phân phối loan_amount khác nhau giữa hai nhóm Status.
- **Lý do chọn biến:** Số tiền vay có thể liên quan đến tình trạng khoản vay. Phân tích này nhằm kiểm tra liệu các khoản vay thuộc hai nhóm Status có sự khác biệt về số tiền vay hay không.

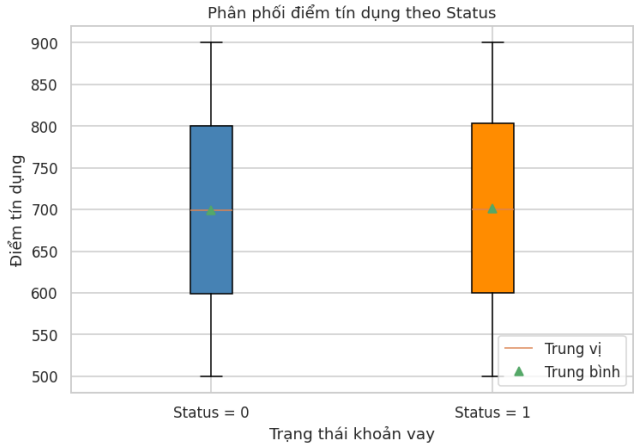


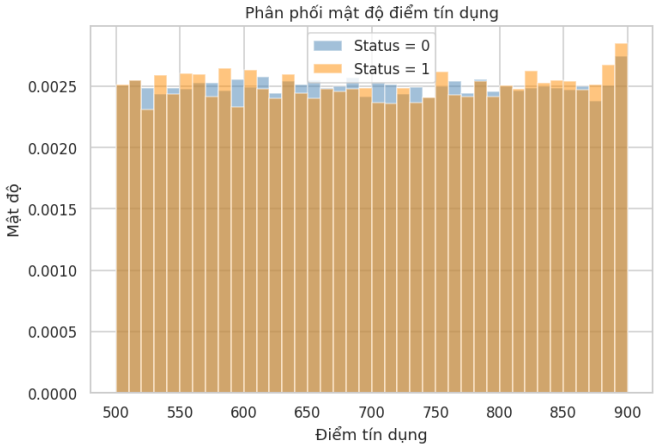
Nhận xét:

- **Phân phối:** Nhóm Status = 1 có trung vị số tiền vay thấp hơn nhóm Status = 0 (276.500 so với 306.500), ngược với kỳ vọng ban đầu. Tuy nhiên, nhóm Status = 1 có độ phân tán lớn hơn và giá trị vay tối đa cũng cao hơn.
- **Kiểm định:** Mann–Whitney U cho kết quả $p < 0{,}001$, nên bác bỏ H_0. Rank-biserial r = **0,0922**, cho thấy mức độ khác biệt về thứ hạng số tiền vay giữa hai nhóm rất nhỏ.
- **Ý nghĩa và giới hạn:** Kết quả cho thấy số tiền vay có mối liên hệ yếu với Status khi xét riêng biến này. Phân tích chưa kiểm soát các yếu tố khác như thu nhập, giá trị tài sản hoặc đặc điểm khoản vay. Các biến LTV và dtir1 sẽ được xem xét thêm ở những phần tiếp theo.
- **Kết luận:** số tiền vay tuyệt đối không phải yếu tố rủi ro, vì khoản vay lớn thường đi kèm tài sản và thu nhập lớn

3.4. Điểm tín dụng (Credit_Score) và Status

- **H_0:** Phân phối Credit_Score giống nhau giữa hai nhóm Status.
- **H_1:** Phân phối Credit_Score khác nhau giữa hai nhóm Status.
- **Lý do chọn biến:** Điểm tín dụng thường được sử dụng để đánh giá mức độ rủi ro của người vay. Phân tích này nhằm kiểm tra liệu nhóm Status = 1 có xu hướng có điểm tín dụng thấp hơn nhóm Status = 0 hay không.



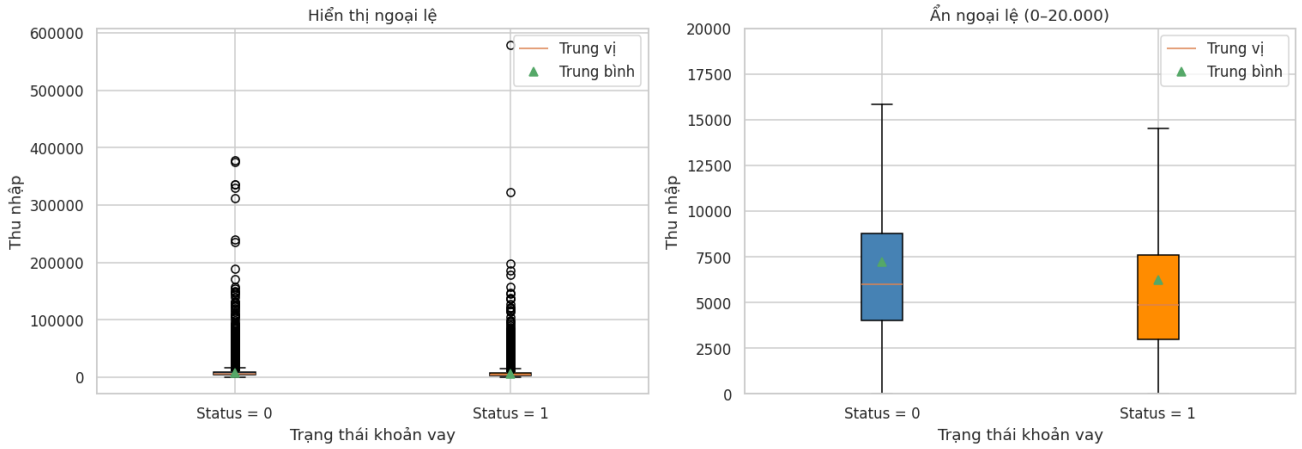


Nhận xét:

- **Phân phối:** Điểm tín dụng của hai nhóm gần như tương đương, với trung vị lần lượt là 699 và 700, trung bình khoảng 699,5 và 700,6. Histogram cho thấy phân phối của hai nhóm chồng lấn rất nhiều và có dạng gần đều trong khoảng 500-900.
- **Kiểm định:** Mann-Whitney U cho kết quả **p = 0,124 > 0,05**, nên chưa đủ bằng chứng bác bỏ H_0. Rank-biserial r = **-0,0053**, cho thấy mức độ khác biệt về thứ hạng gần như bằng 0.
- **Ý nghĩa:** Kết quả không thể hiện xu hướng nhóm Status = 1 có điểm tín dụng thấp hơn như kỳ vọng ban đầu. Đặc điểm phân phối gần đều cũng đáng chú ý, nhưng chưa đủ cơ sở để xác định nguyên nhân.
- **Giới hạn:** Kết quả này chỉ cho thấy chưa phát hiện sự khác biệt có ý nghĩa thống kê giữa hai nhóm. Không thể kết luận rằng điểm tín dụng không có giá trị trong thực tế hoặc hai phân phối hoàn toàn giống nhau.

3.5. Thu nhập (income) và Status

- **H_0:** Phân phối income giống nhau giữa hai nhóm Status.
- **H_1:** Phân phối income khác nhau giữa hai nhóm Status.
- **Lý do chọn biến:** Thu nhập có thể liên quan đến khả năng trả nợ. Phân tích này nhằm kiểm tra liệu nhóm Status = 1 có xu hướng có thu nhập thấp hơn nhóm Status = 0 hay không.
- **Xử lý dữ liệu thiếu:** Sử dụng df_clean và loại các giá trị NaN của income khi phân tích. Các giá trị thiếu được giữ nguyên ở Giai đoạn 2 để tránh thay thế khi chưa có đủ cơ sở.



Nhận xét:

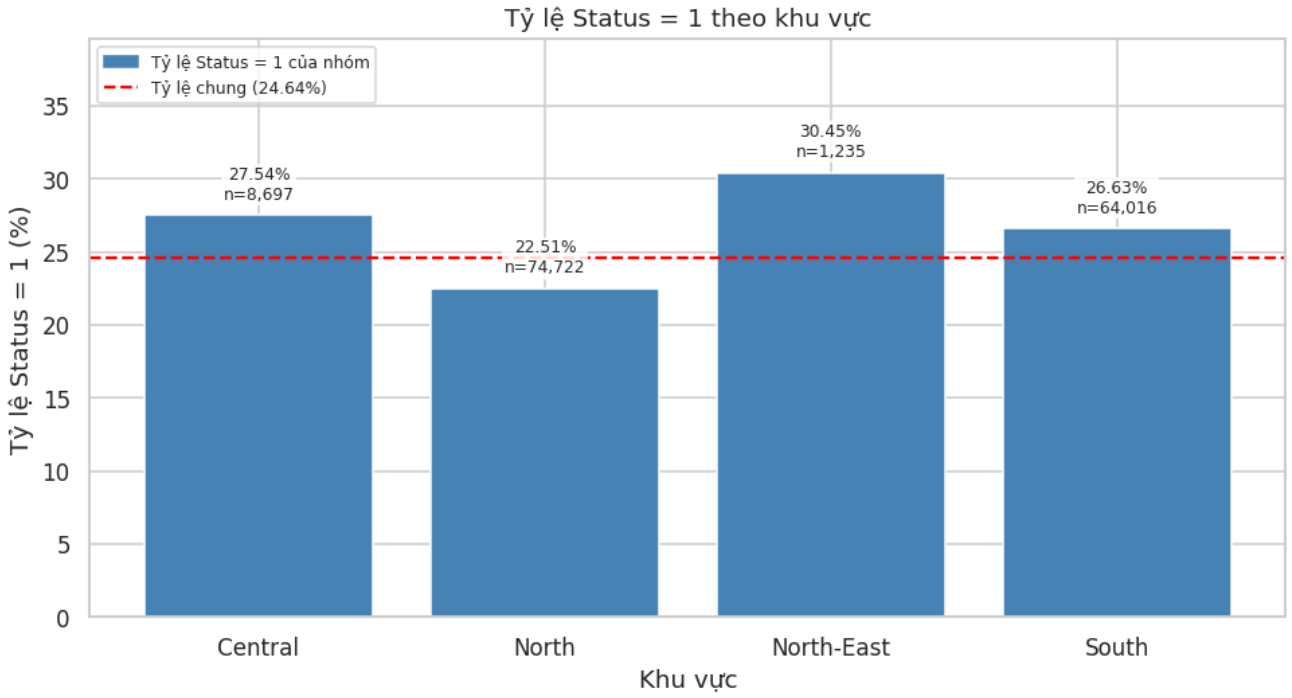
- **Phân phối:** Nhóm Status = 1 có trung vị thu nhập **4.860**, thấp hơn nhóm Status = 0 (**6.000**) khoảng 19%. Cả hai nhóm đều có nhiều giá trị ngoại lệ lớn, khiến sự khác biệt khó quan sát trên biểu đồ đầy đủ.
- **Kiểm định:** Mann–Whitney U cho kết quả **$p < 10^{-300}$**, nên bác bỏ H_0. Rank-biserial r = **0,1846**, cho thấy mức độ khác biệt nhỏ, với xu hướng thu nhập cao hơn ở nhóm Status = 0.
- **Phân tích độ nhạy:** Khi loại 1.260 quan sát có income = 0, rank-biserial r giảm từ **0,1846 xuống 0,1547**. Tuy nhiên, chiều khác biệt và ý nghĩa thống kê vẫn không thay đổi. Điều này cho thấy kết quả không hoàn toàn phụ thuộc vào các giá trị thu nhập bằng 0.
- **Giới hạn:** Tỷ lệ thiếu thu nhập khác nhau giữa hai nhóm Status, có thể ảnh hưởng đến kết quả so sánh. Ngoài ra, đơn vị và kỳ tính thu nhập chưa được xác nhận, nên chỉ diễn giải sự khác biệt tương đối giữa hai nhóm.
- **Diễn giải:** Trung vị thu nhập của nhóm vỡ nợ là 4.860, thấp hơn nhóm không vỡ nợ (6.000) khoảng 19%. Kết quả không thay đổi khi bỏ các giá trị 0, nên thu nhập thấp là một yếu tố rủi ro thực sự. Cần phân biệt "thu nhập bằng 0" với "không khai báo thu nhập" khi nhập liệu.
- **Kết luận:** thu nhập thấp là yếu tố rủi ro thực sự, vẫn đúng khi bỏ các giá trị 0.

3.6. Khu vực (Region) và Status

- **H_0:** Region và Status độc lập với nhau.
- **H_1:** Có mối liên hệ giữa Region và Status.
- **Lý do chọn biến:** Phân tích nhằm kiểm tra liệu tỷ lệ Status = 1 có khác nhau giữa các khu vực hay không. Kết quả giúp nhận diện sự khác biệt theo khu vực, nhưng không chứng minh vị trí địa lý là nguyên nhân dẫn đến tình trạng khoản vay.

	Region	0	1
0	Central	6302	2395
1	North	57901	16821
2	North-East	859	376
3	South	46969	17047

	Region	0	1
0	Central	72.46	27.54
1	North	77.49	22.51
2	North-East	69.55	30.45
3	South	73.37	26.63



Nhận xét:

- **Phân phối:** North-East có tỷ lệ Status = 1 cao nhất (**30,45%**), nhưng chỉ có 1.235 quan sát. North có tỷ lệ thấp nhất (**22,51%**), trong khi Central (27,54%) và South (26,63%) đều cao hơn mức chung 24,64%.
- **Kiểm định:** Chi-square cho kết quả $\chi^2 = 380{,}46$, $p < 0{,}001$, nên bác bỏ H_0. Các tần số kỳ vọng đáp ứng điều kiện áp dụng kiểm định.
- **Mức độ liên hệ:** Cramér's V = **0,051**, cho thấy mối liên hệ giữa Region và Status rất yếu, dù có ý nghĩa thống kê.
- **Ý nghĩa và giới hạn:** Sự khác biệt giữa các khu vực có thể liên quan đến điều kiện kinh tế hoặc đặc điểm khoản vay, nhưng phân tích hiện tại chưa kiểm soát các yếu tố này. Vì vậy, không thể kết luận khu vực trực tiếp ảnh hưởng đến tình trạng khoản vay hoặc sử dụng kết quả làm căn cứ từ chối tín dụng theo khu vực.
- **Kết luận:** khu vực gần như không phân biệt được rủi ro.

3.7. Ma trận tương quan giữa các thuộc tính tài chính

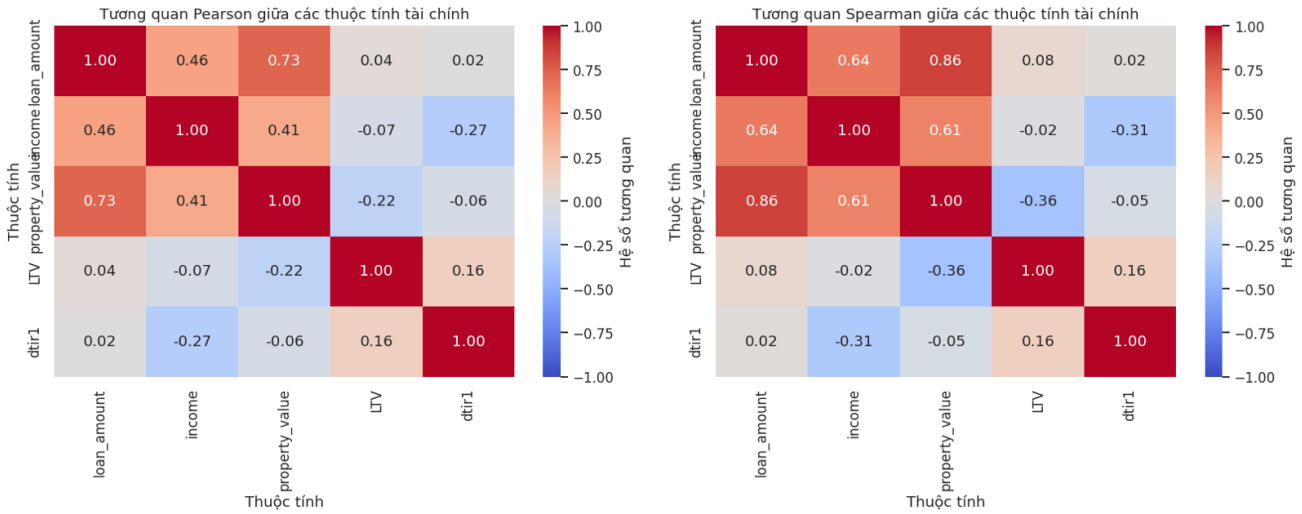
- **Mục tiêu:** Xem xét mức độ và chiều tương quan giữa các thuộc tính tài chính, đồng thời phát hiện những cặp biến có tương quan cao hoặc có thể chứa thông tin trùng lặp.
- Giả định ban đầu: số tiền vay, giá trị tài sản và thu nhập tăng cùng nhau; LTV ngược chiều giá trị tài sản; thu nhập ngược chiều dtir1
- **Phương pháp:** Sử dụng cả Pearson và Spearman. Pearson đo mối liên hệ tuyến tính, trong khi Spearman đo mối liên hệ đơn điệu dựa trên thứ hạng và ít nhạy hơn với các giá trị ngoại lệ.
- **Xử lý dữ liệu thiếu:** Giữ nguyên các giá trị NaN trong df_clean. Khi tính tương quan, mỗi cặp biến chỉ sử dụng những quan sát có đủ giá trị của cả hai biến (*pairwise deletion*).

	loan_amount	income	property_value	LTV	dtir1
loan_amount	1.00	0.46	0.73	0.04	0.02
income	0.46	1.00	0.41	-0.07	-0.27
property_value	0.73	0.41	1.00	-0.22	-0.06
LTV	0.04	-0.07	-0.22	1.00	0.16
dtir1	0.02	-0.27	-0.06	0.16	1.00

	loan_amount	income	property_value	LTV	dtir1

loan_amount	1.00	0.64	0.86	0.08	0.02
income	0.64	1.00	0.61	-0.02	-0.31
property_value	0.86	0.61	1.00	-0.36	-0.05
LTV	0.08	-0.02	-0.36	1.00	0.16
dtir1	0.02	-0.31	-0.05	0.16	1.00

	loan_amount	income	property_value	LTV	dtir1
loan_amount	148670	139520	133572	133572	124549
income	139520	139520	124437	124437	124439
property_value	133572	124437	133572	133572	124547
LTV	133572	124437	133572	133572	124547
dtir1	124549	124439	124547	124547	124549



Nhận xét:

- **Tương quan nổi bật:** loan_amount và property_value có tương quan dương mạnh nhất (Pearson = 0,73; Spearman = 0,86). income cũng có tương quan dương với hai biến này, đặc biệt theo Spearman (0,61–0,64). Điều này cho thấy các khoản vay lớn thường đi kèm giá trị tài sản và thu nhập cao hơn.
- **So sánh Pearson và Spearman:** Một số cặp biến có hệ số Spearman lớn hơn Pearson về độ lớn, chẳng hạn loan_amount–income (0,64 so với 0,46). Sự khác biệt này có thể liên quan đến ngoại lệ hoặc hình dạng mối quan hệ giữa các biến, nhưng cần phân tích thêm để xác định nguyên nhân.
- **Các tỷ lệ tài chính:** LTV tương quan âm với property_value (Spearman = -0,36), phù hợp với việc giá trị tài sản nằm ở mẫu số của công thức LTV. income cũng tương quan âm với dtir1 (Spearman = −0,31), phù hợp với ý nghĩa của tỷ lệ nợ trên thu nhập.
- **Giới hạn:** Các kết quả chỉ phản ánh tương quan giữa từng cặp thuộc tính, chưa đủ để kết luận về đa cộng tuyến trong một mô hình cụ thể. Ngoài ra, mỗi hệ số được tính trên những quan sát có đủ dữ liệu của cặp biến tương ứng, nên tình trạng thiếu dữ liệu có thể ảnh hưởng đến kết quả.
- **Kết luận:** điều này giải thích vì sao số tiền vay lớn không rủi ro hơn

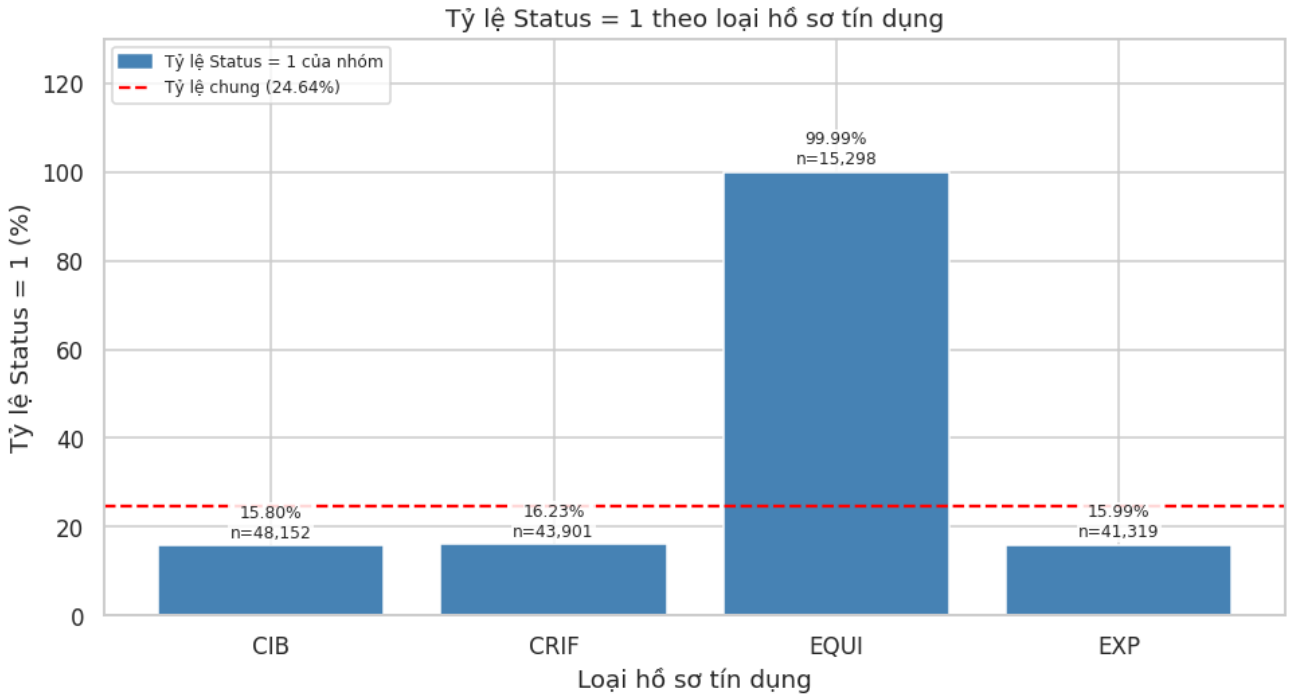
3.8. Loại hồ sơ tín dụng (credit_type) và Status

- **H_0:** credit_type và Status độc lập với nhau.
- **H_1:** Có mối liên hệ giữa credit_type và Status.
- **Lý do chọn biến:** Ở mục 3.4, Credit_Score không cho thấy sự khác biệt có ý nghĩa thống kê giữa hai nhóm Status. Vì vậy, phân tích này nhằm kiểm tra liệu tỷ lệ Status = 1 có khác nhau giữa các loại hồ sơ tín dụng hay không.
- **Lưu ý:** Ý nghĩa cụ thể của các mã EXP, EQUI, CRIF và CIB chưa được xác nhận trong tài liệu nguồn.

	credit_type	Status=0	Status=1	Status=0 (%)	Status=1 (%)
0	CIB	40542	7610	84.20	15.80
1	CRIF	36774	7127	83.77	16.23
2	EQUI	1	15297	0.01	99.99
3	EXP	34714	6605	84.01	15.99

	Chi-square	df	p-value	Cramér's V	Mức độ	Tần số kỳ vọng nhỏ nhất	% ô có kỳ vọng < 5

0	52135.2807	3	< 1e-300	0.5922	Lớn	3770.1	0.0



	credit_type	Không thiếu	Thiếu
0	CIB	40542	7610
1	CRIF	36774	7127
2	EQUI	1	15297
3	EXP	34714	6605

Nhận xét:

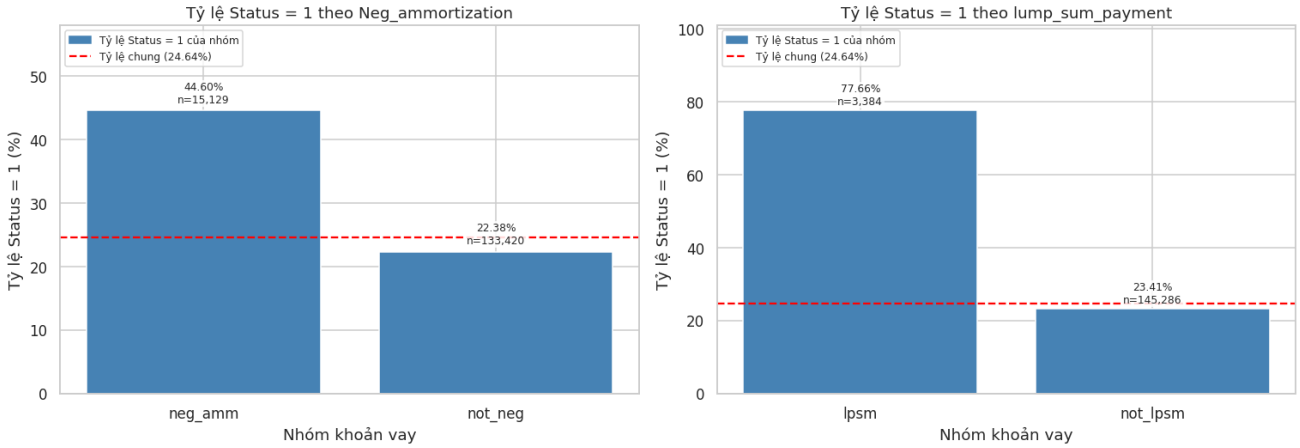
- **Phân phối:** EQUI có tỷ lệ Status = 1 gần như tuyệt đối (**99,99%**, tương ứng 15.297/15.298 quan sát), trong khi ba nhóm còn lại chỉ khoảng 15,8–16,2%.
- **Kiểm định:** Chi-square cho kết quả $\chi^2 = 52.135,28$, $p < 0,001$, nên bác bỏ H_0. Cramér's V = **0,5922**, cho thấy mối liên hệ mạnh giữa credit_type và Status.
- **Ảnh hưởng của EQUI:** Nhóm EQUI chiếm **41,75%** tổng số quan sát có Status = 1. Khi loại nhóm này, tỷ lệ Status = 1 trong phần dữ liệu còn lại giảm từ 24,64% xuống khoảng 16%.
- **Dữ liệu thiếu:** Có 15.297/15.298 quan sát thuộc EQUI thiếu Interest_rate_spread. Đây là một đặc điểm đáng chú ý, nhưng chưa đủ để xác định nguyên nhân.
- **Diễn giải:** EQUI có tỷ lệ vỡ nợ 99,99% (15.297/15.298 khoản), trong khi CIB, CRIF, EXP chỉ khoảng 16%. EQUI chiếm 41,75% số khoản vỡ nợ và gần như toàn bộ thiếu Interest_rate_spread. Một biến gần như trùng với nhãn là bất thường, có thể là rò rỉ nhãn (EQUI được ghi nhận sau khi khoản vay đã vỡ nợ)
- **Ý nghĩa và giới hạn:** Mối liên hệ gần như tuyệt đối giữa EQUI và Status cần được kiểm tra thêm. Nếu xây dựng mô hình dự đoán, cần xác minh ý nghĩa và thời điểm ghi nhận credit_type để đánh giá nguy cơ rò rỉ nhãn (*target leakage*). Kết quả này không chứng minh loại hồ sơ tín dụng trực tiếp gây ra tình trạng khoản vay.
- **Kết luận:** biến gần như trùng với nhãn là dấu hiệu rò rỉ nhãn.

3.9. Đặc điểm cấu trúc trả nợ: Neg_ammortization và lump_sum_payment

- **H_0:** Mỗi biến Neg_ammortization và lump_sum_payment độc lập với Status.
- **H_1:** Có mối liên hệ giữa ít nhất một trong hai biến và Status.
- **Lý do chọn biến:** Hai biến này phản ánh đặc điểm của phương thức trả nợ. Phân tích nhằm kiểm tra liệu tỷ lệ Status = 1 có khác nhau giữa các nhóm khoản vay hay không.
- **Xử lý dữ liệu thiếu:** Nhóm Unknown của Neg_ammortization (121 quan sát) được loại khỏi phép so sánh hai nhóm và kiểm định Chi-square.

	Neg_ammortization	0	1
0	neg_amm	8382	6747
1	not_neg	103560	29860

	lump_sum_payment	0	1
0	lpsm	756	2628
1	not_lpsm	111275	34011



Nhận xét:

- **Neg_ammortization:** Nhóm neg_amm có tỷ lệ Status = 1 là **44,60%**, cao gần gấp đôi nhóm not_neg (22,38%), với **RR = 1,99**. Cramér's V = **0,1559**, cho thấy mức độ liên hệ nhỏ.
- **lump_sum_payment:** Nhóm lpsm có tỷ lệ (vỡ nợ) Status = 1 lên tới **77,66%**, so với 23,41% ở nhóm not_lpsm, tương ứng **RR = 3,32**. Tuy nhiên, nhóm lpsm chỉ có 3.384 quan sát. Cramér's V = **0,1877**, mức độ liên hệ nhỏ.
- **Kiểm định:** Cả hai biến đều có p < 0,001, nên bác bỏ H_0 trong từng kiểm định. Các bảng đều đáp ứng điều kiện về tần số kỳ vọng.
- **Ý nghĩa và giới hạn:** Hai đặc điểm cấu trúc trả nợ có sự khác biệt đáng chú ý về tỷ lệ Status = 1, đặc biệt là lump_sum_payment. Tuy nhiên, phân tích chưa kiểm soát các yếu tố khác như thu nhập, LTV hoặc loại khoản vay. Vì vậy, kết quả chỉ cho thấy mối liên hệ, không chứng minh cấu trúc trả nợ trực tiếp gây ra tình trạng khoản vay.
- **Kết luận:** đây là yếu tố rủi ro rõ nhất, vì trả gốc dồn cuối kỳ hoặc dư nợ tăng dần tạo áp lực trả nợ lớn.

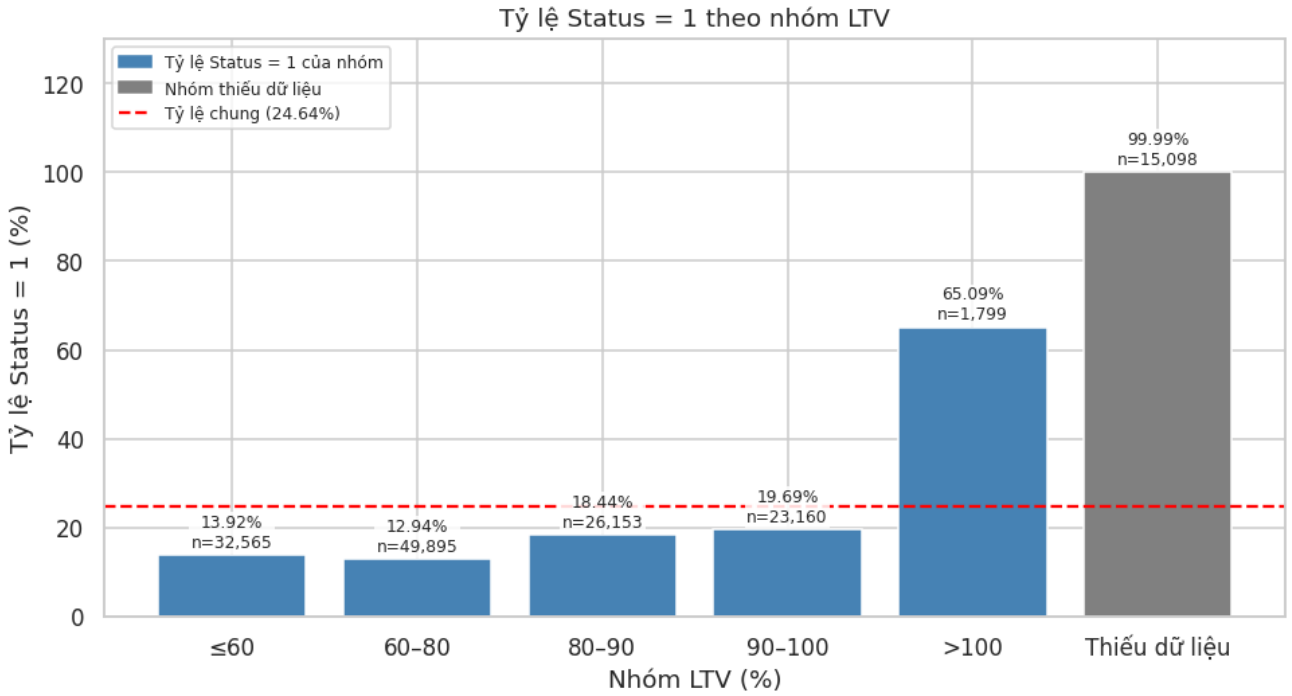
3.10. LTV và Status: Phân tích ảnh hưởng của dữ liệu thiếu

- **H_0:** Phân phối LTV giống nhau giữa hai nhóm Status có dữ liệu LTV.
- **H_1:** Phân phối LTV khác nhau giữa hai nhóm Status có dữ liệu LTV.
- **Lý do chọn biến:** LTV thể hiện tỷ lệ số tiền vay so với giá trị tài sản. Phân tích nhằm kiểm tra mối liên hệ giữa LTV và Status.
- **Vấn đề dữ liệu thiếu:** LTV thiếu ở khoảng 41,20% nhóm Status = 1, nhưng gần như không thiếu ở nhóm Status = 0. Vì vậy, nếu chỉ sử dụng các giá trị có sẵn, kết quả có thể bị ảnh hưởng bởi sự khác biệt về tình trạng thiếu dữ liệu.
- **Phương pháp:** Chia LTV thành các khoảng, bổ sung nhóm **"Thiếu dữ liệu"** để xem xét phân bố Status. Đồng thời, thực hiện kiểm định Mann–Whitney U trên những quan sát có giá trị LTV và báo cáo rõ cỡ mẫu.

	Nhóm LTV	Status=0	Status=1	Tỷ lệ Status=1 (%)
0	≤60	28031	4534	13.92
1	60–80	43439	6456	12.94
2	80–90	21331	4822	18.44
3	90–100	18600	4560	19.69
4	>100	628	1171	65.09
5	Thiếu dữ liệu	2	15096	99.99

	Trường hợp	Chi-square	df	p-value	Cramér's V	Mức độ	Tần số kỳ vọng nhỏ nhất	% ô có kỳ vọng < 5
0	Có nhóm thiếu dữ liệu	54279.4134	5	< 1e-300	0.6042	Lớn	443.4	0.0
1	Chỉ nhóm có LTV	4000.7954	4	< 1e-300	0.1731	Nhỏ	290.1	0.0

	U	p-value	Rank-biserial r	Mức độ	n (Status=0)	n (Status=1)	Median (Status=0)	Median (Status=1)
0	1.035994e+09	6.022e-238	-0.1415	Nhỏ	112029	21543	74.504405	79.362416



Nhận xét:

- **Các nhóm có LTV:** Tỷ lệ Status = 1 dao động từ **12,94% đến 19,69%** ở các nhóm LTV không vượt quá 100%, nhưng tăng lên **65,09%** ở nhóm LTV trên 100%. Nhóm này có 1.799 quan sát.
- **Kiểm định:** Khi chỉ xét các nhóm có LTV, Chi-square cho $p < 0,001$ và Cramér's V = **0,1731**, cho thấy mức độ liên hệ nhỏ. Kiểm định Mann–Whitney cũng cho $p < 0,001$, với trung vị LTV của nhóm Status = 1 cao hơn nhóm Status = 0 (79,36 so với 74,50) và rank-biserial r = **−0,1415**.
- **Ảnh hưởng của dữ liệu thiếu:** Trong 15.098 quan sát thiếu LTV, có **15.096 quan sát thuộc Status = 1**. Khi đưa nhóm thiếu dữ liệu vào bảng Chi-square, Cramér's V tăng lên **0,6042**. Điều này cho thấy tình trạng thiếu LTV có mối liên hệ rất mạnh với Status và ảnh hưởng đáng kể đến kết quả phân tích tổng thể.
- **Ý nghĩa và giới hạn:** Nhóm LTV trên 100% có tỷ lệ Status = 1 cao hơn rõ rệt so với các nhóm còn lại. Tuy nhiên, kết quả chỉ phản ánh dữ liệu có LTV được ghi nhận. Việc thiếu dữ liệu không đồng đều giữa hai nhóm Status, cùng với sáu giá trị LTV cực đoan nghi ngờ lỗi, cần được cân nhắc khi diễn giải. Chưa thể kết luận quan hệ nhân quả.

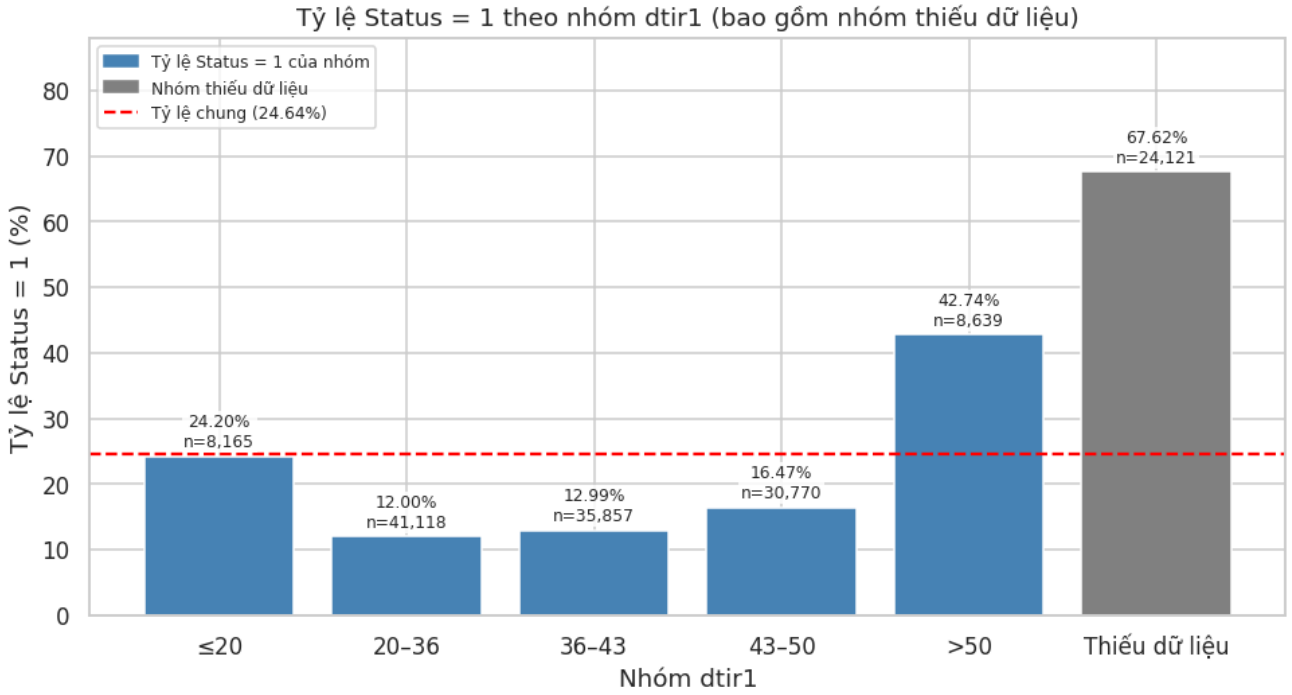
3.11. Tỷ lệ nợ trên thu nhập (dtir1) và Status

- **H_0:** Phân phối dtir1 giống nhau giữa hai nhóm Status có dữ liệu.
- **H_1:** Phân phối dtir1 khác nhau giữa hai nhóm Status có dữ liệu.
- **Lý do chọn biến:** dtir1 phản ánh tỷ lệ nghĩa vụ nợ so với thu nhập. Phân tích nhằm kiểm tra liệu nhóm Status = 1 có xu hướng có DTI cao hơn nhóm Status = 0 hay không.
- **Vấn đề dữ liệu thiếu:** dtir1 thiếu ở 44,52% nhóm Status = 1, so với 6,97% nhóm Status = 0. Sự khác biệt này có thể ảnh hưởng đến kết quả phân tích.
- **Phương pháp:** Tương tự mục 3.10, chia DTI thành các khoảng và giữ riêng nhóm "Thiếu dữ liệu". Đồng thời, thực hiện kiểm định Mann–Whitney U trên các giá trị có sẵn và báo cáo rõ cỡ mẫu.

	Nhóm DTI	Status=0	Status=1	Tỷ lệ Status=1 (%)
0	≤20	6189	1976	24.20
1	20–36	36183	4935	12.00
2	36–43	31199	4658	12.99
3	43–50	25702	5068	16.47
4	>50	4947	3692	42.74
5	Thiếu dữ liệu	7811	16310	67.62

	Trường hợp	Chi-square	df	p-value	Cramér's V	Mức độ	Tần số kỳ vọng nhỏ nhất	% ô có kỳ vọng < 5
0	Có nhóm thiếu dữ liệu	32777.2661	5	< 1e-300	0.4695	Trung bình	2012.2	0.0
1	Chỉ nhóm có DTI	5638.0753	4	< 1e-300	0.2128	Nhỏ	1332.7	0.0

	U	p-value	Rank-biserial r	Mức độ	n (Status=0)	n (Status=1)	Median (Status=0)	Median (Status=1)
0	901116149.5	6.890e-250	-0.1494	Nhỏ	104220	20329	38.0	42.0



Nhận xét:

- **Phân phối:** Tỷ lệ vỡ nợ thấp nhất ở nhóm 20-36 (12,00%) và tăng lên 42,74% ở nhóm trên 50; nhưng nhóm ≤ 20 lại khá cao (24,20%), nên quan hệ có hình chữ J chứ không tăng đều. Nhóm thiếu dữ liệu có tỷ lệ 67,62%. Nhận định: dtir1 > 50 là ngưỡng cảnh báo; nhóm ≤ 20 cần kiểm tra thêm vì có thể khai báo thu nhập chưa chính xác.
- **Kiểm định:** Khi chỉ xét các nhóm có dữ liệu, Chi-square cho p < 0,001 và Cramér's V = **0,2128**, cho thấy mức độ liên hệ nhỏ. Kiểm định Mann–Whitney cũng cho p < 0,001, với trung vị dtir1 của nhóm Status = 1 cao hơn nhóm Status = 0 (42 so với 38) và rank-biserial r = **−0,1494**.
- **Ảnh hưởng của dữ liệu thiếu:** Trong 24.121 quan sát thiếu dtir1, có 16.310 quan sát thuộc Status = 1 (**67,62%**). Khi đưa nhóm thiếu dữ liệu vào kiểm định Chi-square, Cramér's V tăng từ **0,2128 lên 0,4695**, cho thấy tình trạng thiếu dtir1 có liên hệ đáng kể với Status.
- **Ý nghĩa và giới hạn:** Nhóm có dtir1 trên 50 có tỷ lệ Status = 1 cao hơn rõ rệt so với các nhóm còn lại, nhưng chưa thể xác định nguyên nhân. Kiểm định Mann–Whitney chỉ sử dụng **20.329/36.639** quan sát thuộc Status = 1. Ngoài ra, đơn vị và cách tính chính xác của dtir1 chưa được xác nhận, nên các ngưỡng phân nhóm chỉ mang tính tham khảo.

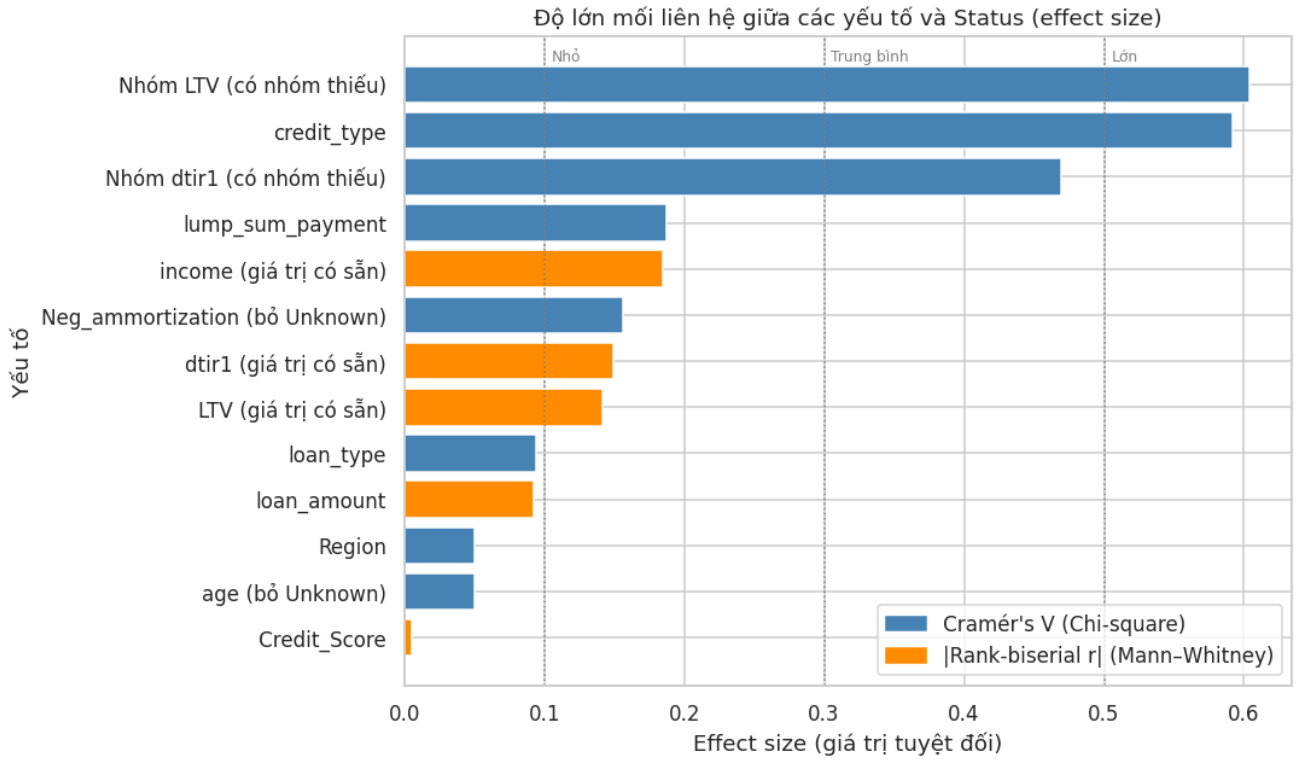
3.12. Tổng hợp kết quả kiểm định và hiệu chỉnh Bonferroni

Bảng dưới đây tổng hợp các kiểm định đã thực hiện trong Giai đoạn 3, bao gồm p-value và effect size để đánh giá cả ý nghĩa thống kê lẫn mức độ liên hệ.

Do thực hiện nhiều kiểm định, phương pháp **Bonferroni** được áp dụng với ngưỡng ý nghĩa điều chỉnh bằng 0,05 chia cho số kiểm định trong nhóm giả thuyết chính.

Các kết quả được sắp xếp theo độ lớn effect size để thuận tiện so sánh. Tuy nhiên, Cramér's V và rank-biserial r là hai thước đo khác nhau nên không thể so sánh trực tiếp hoàn toàn.

Chỉ báo thiếu Interest_rate_spread được trình bày riêng làm **mốc tham chiếu về tình trạng thiếu dữ liệu gắn với Status**, không được xem là yếu tố rủi ro tín dụng.



Nhận xét tổng hợp:

- **Ý nghĩa thống kê:** Trong 13 kiểm định chính, có **12 kiểm định đạt ý nghĩa thống kê** sau hiệu chỉnh Bonferroni (ngưỡng α = 0,00385). Chỉ Credit_Score không đạt ý nghĩa thống kê (p = 0,124). Do cỡ mẫu lớn, cần xem xét cả effect size thay vì chỉ dựa vào p-value.

- **Mối liên hệ mạnh nhất:** Nhóm LTV có tính cả dữ liệu thiếu (Cramér's V = **0,6042**) và credit_type (**0,5922**) có mức liên hệ lớn nhất trong các kiểm định chính. Nhóm dtir1 có tính cả dữ liệu thiếu cũng có mức liên hệ đáng kể (V = **0,4695**). Tuy nhiên, các kết quả này chịu ảnh hưởng của tình trạng thiếu dữ liệu hoặc những nhóm có phân bố Status rất khác biệt, nên cần diễn giải thận trọng.

- **Các mối liên hệ nhỏ:** lump_sum_payment (V = 0,1877), income (|r| = 0,1846), Neg_ammortization (V = 0,1559), dtir1 (|r| = 0,1494) và LTV (|r| = 0,1415) trên các giá trị có sẵn đều cho thấy mức độ liên hệ nhỏ với Status.

- **Các mối liên hệ rất yếu:** loan_type, loan_amount, Region và age đều có effect size dưới 0,1 dù đạt ý nghĩa thống kê. Riêng Credit_Score có effect size gần bằng 0 và không đạt ý nghĩa thống kê.

- **Giới hạn:** Cramér's V và rank-biserial r đo những khía cạnh khác nhau nên thứ tự trong biểu đồ chỉ mang tính tham khảo. Các kiểm định đều là phân tích đơn biến, chưa kiểm soát các yếu tố gây nhiễu và không chứng minh quan hệ nhân quả.

Bảng đối chiếu kết quả với giả định ban đầu:

Yếu tố	Giả định ban đầu	Kết quả
Tuổi	Người trẻ và cao tuổi rủi ro hơn	Khớp chiều hướng, rất yếu
Loại khoản vay	type2 rủi ro hơn	Khớp, yếu
Số tiền vay	Vay nhiều rủi ro hơn	Không khớp (ngược chiều)
Điểm tín dụng	Điểm thấp rủi ro hơn	Không khớp (không khác biệt)
Thu nhập	Thu nhập thấp rủi ro hơn	Khớp, mức nhỏ

Khu vực	Chênh lệch nhỏ	Khớp
Tương quan tài chính	Đúng chiều theo công thức	Khớp
Loại hồ sơ tín dụng	Chênh lệch nhỏ	Không khớp (EQUI gần 100% vỡ nợ)
Cấu trúc trả nợ	lpsm, neg_amm rủi ro hơn	Khớp (rủi ro gấp 3,32 và 1,99 lần)
LTV	Càng cao càng rủi ro	Khớp phần lớn (LTV > 100%: 65,09%)
dtir1	Càng cao càng rủi ro	Khớp một phần (hình chữ J)

3.13. Kiểm tra độ bền của kết quả khi loại nhóm EQUI

Lý do: Ở mục 3.8, nhóm credit_type = EQUI có tỷ lệ Status = 1 gần như tuyệt đối (99,99%) và chiếm 41,75% tổng số quan sát thuộc Status = 1. Điều này đặt ra câu hỏi liệu các mối liên hệ đã phát hiện có phụ thuộc nhiều vào nhóm EQUI hay không.

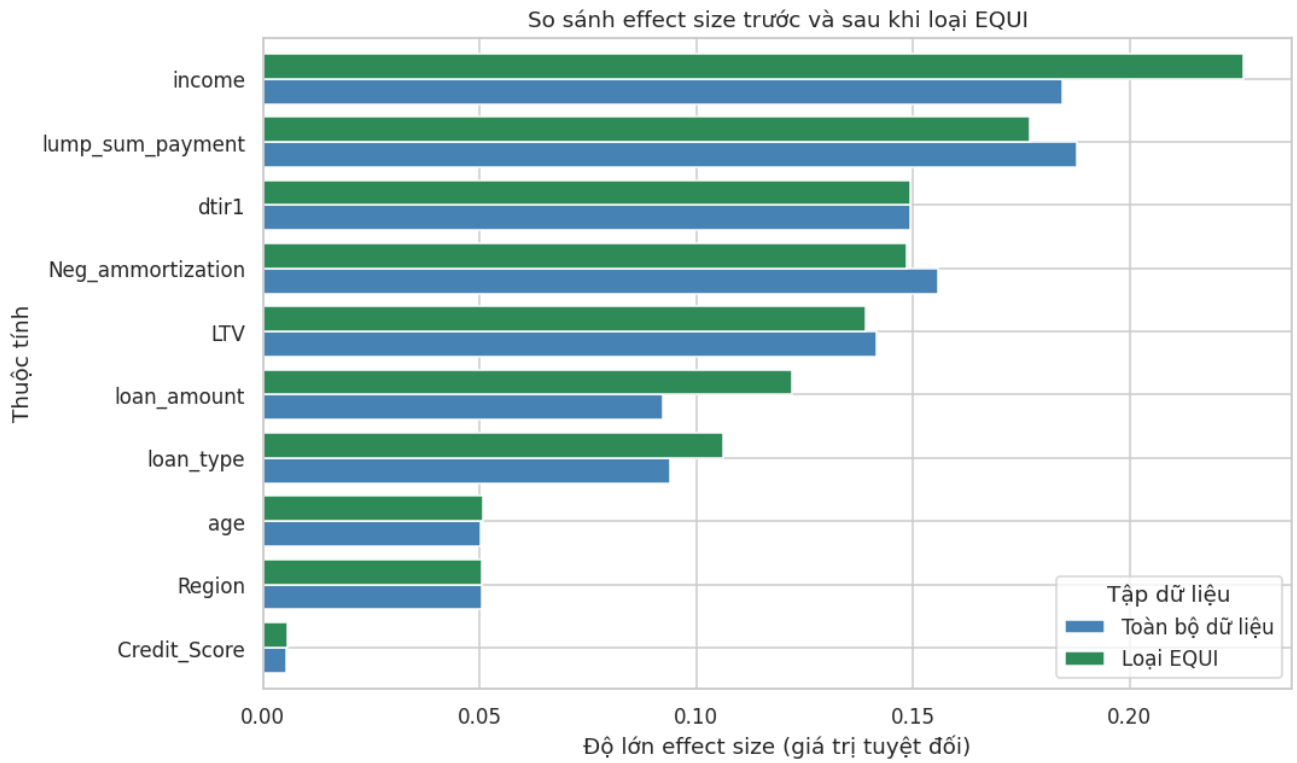
Phương pháp: Loại nhóm EQUI và thực hiện lại các kiểm định chính trên tập dữ liệu còn lại (df_non_equi, gồm 133.372 quan sát). Sau đó, so sánh chiều và độ lớn effect size trước và sau khi loại nhóm này.

Mục tiêu: Đánh giá mức độ ổn định của các kết quả khi thay đổi thành phần mẫu, không nhằm xác định nhóm EQUI là dữ liệu sai.

	Biến	Effect size	Toàn bộ dữ liệu	Loại EQUI	Mức độ khi loại EQUI
0	lump_sum_payment	Cramér's V	0.1877	0.1770	Nhỏ
1	Neg_ammortization	Cramér's V	0.1559	0.1486	Nhỏ
2	loan_type	Cramér's V	0.0939	0.1063	Nhỏ
3	Region	Cramér's V	0.0506	0.0504	Không đáng kể
4	age	Cramér's V	0.0502	0.0509	Không đáng kể
5	income	Rank-biserial r	0.1846	0.2262	Nhỏ
6	dtir1	Rank-biserial r	-0.1494	-0.1494	Nhỏ
7	LTV	Rank-biserial r	-0.1415	-0.1392	Nhỏ
8	loan_amount	Rank-biserial r	0.0922	0.1222	Nhỏ
9	Credit_Score	Rank-biserial r	-0.0053	-0.0057	Không đáng kể

	Nhóm	Toàn bộ (%)	Loại EQUI (%)	n (loại EQUI)
0	≤60	13.92	13.90	32556
1	60–80	12.94	12.86	49846
2	80–90	18.44	18.20	26078
3	90–100	19.69	19.45	23091
4	>100	65.09	65.09	1799
5	Thiếu dữ liệu	99.99	0.00	2

	Nhóm	Toàn bộ (%)	Loại EQUI (%)	n (loại EQUI)
0	≤20	24.20	24.20	8165
1	20–36	12.00	12.00	41117
2	36–43	12.99	12.99	35856
3	43–50	16.47	16.47	30770
4	>50	42.74	42.74	8639
5	Thiếu dữ liệu	67.62	11.49	8825



Nhận xét:

- **Ảnh hưởng của EQUI:** Sau khi loại nhóm EQUI, dữ liệu còn **133.372 khoản vay**, với tỷ lệ Status = 1 giảm từ 24,64% xuống **16,00%**. Tỷ lệ thiếu LTV trong nhóm Status = 1 giảm từ 41,20% xuống 0%, còn tỷ lệ thiếu dtir1 giảm từ 44,52% xuống 4,75%.

- **Các kết quả tương đối ổn định:** Mức độ liên hệ của lump_sum_payment (V: 0,188 → 0,177), Neg_ammortization (0,156 → 0,149), LTV (r: −0,142 → −0,139) và dtir1 (r ≈ −0,149) thay đổi ít. Tỷ lệ Status = 1 ở nhóm LTV trên 100% vẫn là **65,09%**, còn nhóm dtir1 trên 50 vẫn là **42,74%**.

- **Các biến có mức độ liên hệ tăng:** Rank-biserial r của income tăng từ **0,1846 lên 0,2262**, còn loan_amount tăng từ 0,0922 lên 0,1222. Cramér's V của loan_type cũng tăng từ 0,0939 lên 0,1063. Điều này cho thấy mức độ liên hệ của một số biến thay đổi khi loại EQUI.

- **Các biến có liên hệ rất yếu:** age và Region gần như không thay đổi, trong khi Credit_Score tiếp tục có effect size gần bằng 0.

- **Dữ liệu thiếu:** Tỷ lệ Status = 1 trong nhóm thiếu dtir1 giảm từ **67,62% xuống 11,49%** khi loại EQUI. Điều này cho thấy kết quả liên hệ mạnh giữa tình trạng thiếu dtir1 và Status trên toàn bộ dữ liệu phụ thuộc đáng kể vào nhóm EQUI.

- **Kết luận:** Nhiều mối liên hệ vẫn giữ nguyên chiều và có độ lớn tương đối ổn định sau khi loại EQUI. Tuy nhiên, kết quả cũng cho thấy thành phần mẫu ảnh hưởng đáng kể đến một số effect size và cách diễn giải dữ liệu thiếu. Phân tích này không loại bỏ được các yếu tố gây nhiễu hoặc chứng minh quan hệ nhân quả.

Tổng kết Giai đoạn 3

- **Yếu tố rủi ro rõ nhất:** trả gốc một lần (rủi ro gấp 3,3 lần), khấu hao âm (gấp 2 lần), LTV > 100%, dtir1 > 50 và thu nhập thấp; các kết quả này vẫn đúng khi loại EQUI.
- **Yếu tố gần như không phân biệt được rủi ro:** tuổi, khu vực, số tiền vay và Credit_Score.
- **Vấn đề dữ liệu cần lưu ý:** Interest_rate_spread thiếu trùng 100% với Status = 1, mã EQUI gần như trùng nhãn, Credit_Score có phân phối đều bất thường.

Giai đoạn 4. Đánh giá tác động và khuyến nghị

Giả định làm việc: Các khuyến nghị dưới đây tạm coi Status = 1 là nhóm khoản vay **vỡ nợ/có vấn đề**, dựa trên mô tả bài toán của data card (*"classify if any new borrower is likely to default"*). Tuy nhiên, ý nghĩa chính thức của mã Status chưa được tài liệu xác nhận. Nếu cách mã hóa thực tế khác, các khuyến nghị về rủi ro cần được đánh giá lại. Các phát hiện về tình trạng thiếu dữ liệu và mối liên hệ giữa các thuộc tính ở mục 4.1-A vẫn có giá trị về mặt thống kê.

4.1. Các phát hiện nổi bật

Các nhận xét dưới đây sử dụng quy ước Status = 1 là nhóm khoản vay vỡ nợ hoặc có vấn đề. Ý nghĩa chính thức của mã Status chưa được xác nhận, nên các diễn giải về rủi ro vẫn mang tính giả định.

A. Chất lượng dữ liệu và nguy cơ rò rỉ thông tin

Phát hiện	Bằng chứng
Tình trạng thiếu Interest_rate_spread trùng hoàn toàn với Status = 1	Toàn bộ 36.639 khoản Status = 1 đều thiếu, trong khi không khoản Status = 0 nào thiếu. Cramér's V = 1,000.
Xóa toàn bộ dòng có giá trị thiếu sẽ làm mất nhóm Status = 1	Sau dropna(), chỉ còn 98.187 quan sát, tất cả thuộc Status = 0.
credit_type = EQUI có liên hệ đặc biệt mạnh với Status	15.297/15.298 khoản EQUI thuộc Status = 1 (99,99%). Cramér's V = 0,5922.
Tình trạng thiếu LTV có liên quan chặt chẽ đến nhóm EQUI	Sau khi loại EQUI, không còn khoản Status = 1 nào thiếu LTV.
Một số giá trị bất thường cần xác minh	Có 6 khoản LTV trên 1.000%, 1.260 khoản income = 0 và phân phối Credit_Score có dạng gần đều.

Những phát hiện này cho thấy cần đặc biệt thận trọng khi xử lý dữ liệu thiếu và sử dụng các thuộc tính có liên hệ gần như tuyệt đối với Status. Nguy cơ rò rỉ thông tin cần được xác minh dựa trên ý nghĩa và thời điểm ghi nhận các biến.

B. Các mối liên hệ đáng chú ý với Status

Yếu tố	Kết quả chính	Effect size
lump_sum_payment = lpsm	Tỷ lệ Status = 1 là 77,66%, so với 23,41% ở nhóm tham chiếu (RR = 3,32).	V = 0,1877
Neg_ammortization = neg_amm	Tỷ lệ 44,60%, so với 22,38% (RR = 1,99).	V = 0,1559
LTV trên 100%	Tỷ lệ 65,09%, cao hơn các nhóm LTV còn lại.	V = 0,1731 khi chỉ xét các nhóm có LTV
dtir1 trên 50	Tỷ lệ 42,74%; nhóm dtir1 ≤20 cũng có tỷ lệ khá cao (24,20%).	V = 0,2128 khi chỉ xét các nhóm có DTI
income	Trung vị nhóm Status = 1 là 4.860, thấp hơn nhóm Status = 0 (6.000).	Rank-biserial r = 0,1846

Các mối liên hệ trên vẫn giữ nguyên chiều và có mức độ tương đối ổn định khi loại nhóm EQUI. Tuy nhiên, kết quả chỉ phản ánh phân tích đơn biến, chưa kiểm soát đồng thời các yếu tố khác.

C. Các mối liên hệ rất yếu

loan_type (V = 0,0939), loan_amount (r = 0,0922), Region (V = 0,0506) và age (V = 0,0502) đều có effect size nhỏ hơn 0,1 trên toàn bộ dữ liệu.

Dù đạt ý nghĩa thống kê, mức độ liên hệ đơn biến của các thuộc tính này rất yếu. Riêng loan_type và loan_amount có effect size tăng lên lần lượt 0,1063 và 0,1222 sau khi loại nhóm EQUI.

D. Những vấn đề chưa thể kết luận

- **Credit_Score:** Không phát hiện sự khác biệt có ý nghĩa thống kê giữa hai nhóm Status (p = 0,124; r = −0,0053). Kết quả này không chứng minh điểm tín dụng không có giá trị trong thực tế.
- **dtir1 thấp:** Nhóm dtir1 ≤20 có tỷ lệ Status = 1 tương đối cao (24,20%), nhưng chưa xác định được nguyên nhân.
- **Nguồn gốc dữ liệu:** Ý nghĩa của mã EQUI, cơ chế thiếu dữ liệu và cách ghi nhận các biến tài chính cần được xác minh thêm.

Giới hạn chung: Các kết quả chỉ thể hiện mối liên hệ thống kê, không chứng minh quan hệ nhân quả hoặc khả năng dự đoán độc lập của từng thuộc tính.

4.2. Khuyến nghị thực tế

Các khuyến nghị dưới đây dựa trên những phát hiện ở mục 4.1, với mục tiêu cải thiện chất lượng dữ liệu, hỗ trợ đánh giá rủi ro và định hướng các bước phân tích tiếp theo. Những đề xuất liên quan đến chính sách tín dụng cần được kiểm chứng thêm trước khi áp dụng thực tế.

#	Khuyến nghị	Căn cứ	Lĩnh vực
R1	Kiểm tra quy trình ghi nhận dữ liệu: Xác minh nguyên nhân và thời điểm thiếu các thuộc tính tài chính như Interest_rate_spread, rate_of_interest, property_value và dtir1. Đồng thời, làm rõ ý nghĩa của nhóm EQUI.	4.1-A: Dữ liệu thiếu và nhóm EQUI	Quản lý dữ liệu
R2	Phòng tránh rò rỉ dữ liệu khi xây dựng mô hình: Chỉ sử dụng các thuộc tính được xác nhận là có sẵn tại thời điểm dự đoán. Kiểm tra kỹ credit_type, các biến lãi suất và tình trạng thiếu dữ liệu. Đánh giá mô hình bằng nhiều chỉ số như ROC-AUC, PR-AUC, precision và recall, thay vì chỉ dựa vào accuracy.	4.1-A: Nguy cơ rò rỉ dữ liệu	Mô hình hóa
R3	Rà soát cấu trúc trả nợ: Với các khoản lump_sum_payment = lpsm hoặc Neg_ammortization = neg_amm, xem xét thêm khả năng đáp ứng nghĩa vụ thanh toán, đặc biệt là khoản trả cuối kỳ hoặc khả năng dư nợ tăng.	4.1-B: Cấu trúc trả nợ	Kiểm soát rủi ro
R4	Theo dõi các khoản LTV trên 100%: Sử dụng mức này làm dấu hiệu cần kiểm tra thêm giá trị tài sản, số tiền vay và khả năng trả nợ trước khi đưa ra quyết định tín dụng.	4.1-B: LTV trên 100%	Thẩm định
R5	Tăng cường kiểm tra chất lượng dữ liệu: Cảnh báo các giá trị LTV cực đoan, kiểm tra những trường hợp giá trị tài sản thấp bất thường và phân biệt rõ income = 0 với giá trị thu nhập bị thiếu.	4.1-A: Giá trị bất thường	Quản lý dữ liệu
R6	Xem xét thêm khả năng chi trả: Ưu tiên kiểm tra những khoản có dtir1 > 50 và xác minh thông tin thu nhập. Đồng thời, tìm hiểu nguyên nhân nhóm dtir1 ≤ 20 cũng có tỷ lệ Status = 1 tương đối cao.	4.1-B: dtir1 và income	Thẩm định
R7	Xác minh thông tin Credit_Score: Kiểm tra nguồn cung cấp, cách tính và ý nghĩa của thang điểm trước khi sử dụng biến này để đánh giá rủi ro.	4.1-D: Credit_Score	Quản lý dữ liệu
R8	Chú trọng tính công bằng: Không đề xuất sử dụng age, Gender hoặc Region làm tiêu chí từ chối khoản vay dựa trên kết quả phân tích này. Nếu xây dựng mô hình trong tương lai, cần đánh giá nguy cơ phân biệt đối xử và tuân thủ các quy định áp dụng.	4.1-C: Tuổi và khu vực	Quản trị mô hình

4.3. Giới hạn của dữ liệu và hướng mở rộng

Giới hạn

1. **Dữ liệu thiếu:** Nhiều thuộc tính có tỷ lệ thiếu khác nhau rõ rệt giữa hai nhóm Status. Đặc biệt, kiểm định LTV và dtir1 chỉ sử dụng lần lượt 58,80% và 55,48% số quan sát thuộc Status = 1. Vì vậy, kết quả trên các giá trị có sẵn có thể không đại diện cho toàn bộ dữ liệu.

2. **Nguồn gốc và cách lấy mẫu:** Chưa có đủ thông tin về quy trình thu thập dữ liệu, tiêu chí lựa chọn hồ sơ hoặc việc có bao gồm các khoản vay bị từ chối hay không. Điều này hạn chế khả năng áp dụng kết quả cho những nhóm người vay khác.

3. **Nguy cơ rò rỉ dữ liệu:** Tình trạng thiếu Interest_rate_spread trùng hoàn toàn với Status, trong khi credit_type = EQUI gần như chỉ xuất hiện ở nhóm Status = 1. Cần xác minh thời điểm ghi nhận các thuộc tính này trước khi sử dụng trong mô hình dự đoán.

4. **Ý nghĩa thuộc tính chưa rõ:** Cách mã hóa Status, loan_type, credit_type và một số thuộc tính khác chưa được xác nhận đầy đủ. Đơn vị và cách tính của income, term và dtir1 cũng cần được làm rõ.

5. **Giới hạn thời gian:** Dữ liệu chỉ ghi nhận năm 2019 và không có thông tin đầy đủ về thời điểm giải ngân hoặc theo dõi kết quả trả nợ. Vì vậy, chưa thể đánh giá xu hướng hoặc mức độ ổn định của các mối liên hệ theo thời gian.

6. **Giá trị bất thường và thông tin trùng lặp:** Một số giá trị LTV cực đoan, các trường hợp income = 0 và phân phối gần đều của Credit_Score cần được xác minh. Ngoài ra, một số thuộc tính có quan hệ trực tiếp hoặc trùng lặp thông tin, chẳng hạn loan_type và business_or_commercial.

7. **Giới hạn phương pháp:** Các kiểm định chủ yếu xem xét từng thuộc tính riêng lẻ, chưa kiểm soát đồng thời các yếu tố gây nhiễu. Hiệu chỉnh Bonferroni được áp dụng cho 13 kiểm định chính, nhưng không loại bỏ mọi hạn chế của phân tích khám phá. Kết quả

không chứng minh quan hệ nhân quả.

Hướng mở rộng

- **Xác minh thông tin dữ liệu:** Thu thập từ điển dữ liệu chính thức, xác nhận ý nghĩa của Status, các mã thuộc tính, đơn vị đo và nguyên nhân thiếu dữ liệu.
- **Mở rộng dữ liệu theo thời gian:** Sử dụng dữ liệu nhiều năm, có thời điểm ghi nhận và kết quả khoản vay, để đánh giá tính ổn định của các mối liên hệ.
- **Xây dựng mô hình dự đoán:** Có thể thử hồi quy logistic và Gradient Boosting sau khi xác minh các thuộc tính có sẵn tại thời điểm dự đoán. Các bước xử lý dữ liệu phải được thực hiện trong tập huấn luyện để tránh rò rỉ thông tin.
- **Phân tích kết hợp nhiều biến:** Xem xét đồng thời thu nhập, LTV, dtir1 và cấu trúc trả nợ để đánh giá liệu các mối liên hệ còn tồn tại khi kiểm soát những yếu tố khác hay không.
- **Đánh giá tính công bằng:** Nếu xây dựng mô hình, cần kiểm tra kết quả giữa các nhóm nhân khẩu học và khu vực, đồng thời xem xét các yêu cầu pháp lý và đạo đức liên quan.

Kết luận

- **Chất lượng dữ liệu là phát hiện quan trọng nhất.** Tình trạng thiếu Interest_rate_spread trùng hoàn toàn với Status, trong khi nhóm credit_type = EQUI và việc thiếu LTV cũng có mối liên hệ rất mạnh với biến mục tiêu. Vì vậy, cần xem xét kỹ các giá trị thiếu thay vì tự động xóa hoặc thay thế chúng.
- **Một số đặc điểm khoản vay có mối liên hệ đáng chú ý với Status**, gồm cấu trúc trả nợ (lump_sum_payment, Neg_ammortization), LTV trên 100%, dtir1 trên 50 và thu nhập. Các mối liên hệ này nhìn chung có effect size nhỏ nhưng vẫn tương đối ổn định khi loại nhóm EQUI.
- **Tuổi và khu vực có mức độ liên hệ rất yếu** với Status, trong khi Credit_Score không cho thấy sự khác biệt có ý nghĩa thống kê giữa hai nhóm. Những kết quả này không đủ để kết luận các thuộc tính trên không có giá trị trong thực tế.

7. **Kết quả chỉ phản ánh mối liên hệ thống kê trong dữ liệu năm 2019**, chưa chứng minh quan hệ nhân quả. Ngoài ra, việc diễn giải rủi ro còn phụ thuộc vào giả định Status = 1 là khoản vay vỡ nợ. Cần xác minh ý nghĩa các thuộc tính, nguồn gốc và quy trình ghi nhận dữ liệu trước khi xây dựng mô hình dự đoán hoặc áp dụng vào quyết định tín dụng.